

DIRECTION GÉNÉRALE DE L'AVIATION CIVILE



Modélisation et classification de l'adhérence des contaminants aéronautiques en conditions hivernales

Service technique de l'aviation civile
Division Sécurité-Adhérence des pistes

Rédigé par :
Anass El Basraoui

Sous la direction de :
Célien Goossaert

Août 2024

Abstract

Aviation safety, particularly during critical phases of takeoff and landing, depends on optimal runway traction, which is often compromised by winter contaminants such as snow and ice. These factors influence the runway's grip, commonly expressed through the Coefficient of Longitudinal Friction (CFL) and the runway's slipperiness. This report addresses this issue by first validating the data obtained during a campaign organized by STAC and conducted in January 2024 at Montreal Mirabel Airport and then evaluating the database's quality through reproducibility and repeatability studies. The modeling of the CFL is subsequently carried out using variables such as average slip and speed, via piecewise penalized regression approaches and ensemble modeling techniques. Finally, a reverse analysis is performed to classify contaminants based on CFL variations and their interactions with runway conditions. The results provide new insights into the impact of winter contaminants on runway traction, offering a deeper understanding of CFL and laying the foundation for improving the safety of aircraft operations on degraded runway surfaces.

Résumé

La sécurité aérienne, surtout lors des phases critiques de décollage et d'atterrissage, dépend d'une adhérence optimale des pistes, souvent compromise par des contaminants hivernaux tels que la neige et le verglas, qui influencent l'adhérence de la chaussée, communément exprimée au travers du Coefficient de frottement longitudinal (CFL) et l'état de glissance de la chaussée. Ce rapport explore cette problématique en validant d'abord les données obtenues lors d'une campagne organisée par le STAC et réalisée en janvier 2024 sur l'aéroport de Montréal Mirabel et en évaluant la qualité de la base à travers des études de reproductibilité et de répétabilité. La modélisation du CFL est ensuite effectuée en utilisant des variables comme le glissement moyen et la vitesse, via des approches de régression pénalisée par morceaux et de modélisation ensembliste. Enfin, une analyse inverse permet de classer les contaminants en fonction des variations du CFL et de leurs interactions avec les conditions de piste. Les résultats offrent une nouvelle perspective sur l'impact des contaminants hivernaux sur l'adhérence des pistes, via une meilleure compréhension du CFL, posant ainsi les bases pour améliorer la sécurité des opérations aériennes d'état de piste dégradées.

Table des matières

Liste des Abréviations	1
Introduction	2
1 Contexte de l'étude	3
1.1 Présentation de l'expérimentation	3
1.2 Pourquoi modéliser le CFL	4
1.3 Description des variables	5
2 Préparation de la table de données	9
2.1 Nettoyage des données	9
2.2 Validation des observations	9
2.2.1 Importance de définir un critère de stabilité	9
2.2.2 Critère de stabilité et définition des seuils	11
2.3 Détermination des choix des seuils de chaque contaminant	11
2.3.1 Validation des observations en présence des contaminants	11
2.3.2 Synthèse des observations retenues	15
2.4 Étude de la reproductibilité et la répétabilité	16
2.4.1 Définitions et remarques	16
2.4.2 Étude de la reproductibilité	18
2.4.3 Étude de la répétabilité	20
3 Analyse exploratoire	23
3.1 Analyse de forme	23
3.2 Analyse de fond	23
3.2.1 La variable cible	23
3.2.2 Relation variables / variable cible et variables / variables :	24
3.3 Commentaires	26
3.4 La relation entre la nature du contaminant et la différence entre le CFL C et le CFL F	27
3.4.1 L'influence de la nature du contaminant	27
3.4.2 Etude de la relation inverse	29
4 Présentation des méthodes utilisées	31
4.1 Régression linéaire	31
4.2 Régression Logistique Multinomiale	31
4.3 Random Forest	32
4.3.1 Random Forest Regressor	33
4.3.2 Random Forest Classifier	34
4.4 XGBoost	34
4.4.1 XGBoost Regressor	35
4.4.2 XGBoost Classifier	35
4.5 Métriques de régression	35
4.6 Matrice de confusion	36

5	Modélisation du CFL C	38
5.1	Modélisation linéaire par morceau pénalisée	38
5.1.1	Création du Modèle	40
5.1.2	Résultat des modèles	43
5.2	Modèles ensemblistes	50
5.2.1	Résultat des modèles	50
5.2.2	Commentaires	51
6	Classification des contaminants	52
6.1	Classification multimodale et univariée	52
6.1.1	Analyse descriptive de la partie extraite du jeu de données	52
6.1.2	Classification supervisée	53
6.1.3	Visualisation des prédictions	55
6.2	Classification multimodale et multivariée	56
6.2.1	Régression logistique	57
6.2.2	Random Forest Classifier	58
6.2.3	XGBoost Classifier	59
6.2.4	Observations pour une vitesse de 65 km/h et g=15%	60
6.2.5	Commentaire	61
6.3	Ajout de l'écart entre le CFL F et le CFL C comme variable explicative . .	62
	Conclusion	65
	Références	66
	Annexe	67
A	Présentation des critères de validation pour le reste des contaminants	67
B	Présentation des modèles pour le reste des contaminant	71
C	Valeurs des hyperparamètres après optimisation avec la validation croisée 5 blocs	73
C.1	Random Forest Regressor	73
C.2	XGBoost Regressor	74

Liste des figures

1	L'aéroport de Mirabel	3
2	Illustrations de la mission Mirabel	4
3	Coefficient de frottement longitudinal (source : [1])	5
4	Aspect de la courbe du CFL en fonction du glissement par quelque contaminant (source : [2])	10
5	Distribution des observations gardées du contaminant Neige fraîche (B) par vitesse consigne (km/h) et par glissement consigne (%)	12
6	Distribution des observations gardées du contaminant NC.C. par vitesse consigne et par glissement consigne	13
7	Distribution des observations gardées du contaminant Glace par vitesse consigne et par glissement consigne	14
8	Distribution des observations gardées du contaminant Slush par vitesse consigne et par glissement consigne	15
9	forme du tableau des valeurs moyennes, écarts types et seuils par contaminant, vitesse consigne, glissement consigne et heure de mesure	18
10	Écart type des moyennes du CFL C de chaque passage, à 40 km/h	19
11	forme du tableau des valeurs moyennes, écarts types et seuils par contaminant, vitesse consigne et glissement consigne	20
12	Écart type des moyennes du CFL C de chaque groupe, à 40 km/h	21
13	Écart type des moyennes du CFL C de chaque groupe, à 65 km/h	21
14	l'effectif de chaque contaminant et son pourcentage	24
15	Corrélation entre les variables du jeu de données	25
16	La relation linéaire forte entre le glissement et valeur moyenne de glissement	26
17	La relation linéaire forte entre la valeur de CFL C et CFL F	26
18	Différence entre le CFL C et le CFL F par rapport à la nature du contaminant	28
19	Distribution des écarts entre CFL C et CFL F pour chaque contaminant	29
20	Exemple illustratif d'un arbre de décision pour la régression (averaging) ou la classification (voting) (source : [3])	32
21	Écart type des trois variables pour chaque contaminant	38
22	Résultats erronés de la régression linéaire dans l'intervalle de 20 à 100 pour le contaminant N.C. (B) pour la vitesse 65Km/h	39
23	Régression par morceau pour le contaminant Neige fraîche (B)	44
24	Régression par morceau pour le contaminant NC.C.	45
25	Régression par morceau pour le contaminant Glace avec $\lambda_1 = 0.001$, $\lambda_2 = 10$, $\lambda_3 = 0.0055$, $\lambda_4 = 0.0001$,	45
26	Régression par morceau pour le contaminant slush avec $\lambda_1 = 0$, $\lambda_2 = 0.005$, $\lambda_3 = 0$, $\lambda_4 = 0$	46
27	CFL de certains contaminants hivernaux à 65 km/h	47
28	Influence de la vitesse sur le CFL pour le contaminant Neige fraîche (B)	48
29	Influence de la vitesse sur le CFL pour le contaminant NC.C.	48
30	Exemples de performances des modèles ensemblistes	51
31	La relation la valeur de CFL C et la nature du contaminant	53
32	Probabilités moyennes pour chaque intervalle CFL C	56
33	Probabilité d'appartenance à un contaminant en fonction de CFL C	56

34	Coefficients de régression logistique	57
35	Probabilités moyennes pour chaque intervalle CFL C	61
36	Probabilité d'appartenance à un contaminant en fonction de CFL C	62
37	Distribution des observations gardées du contaminant Neige fraiche (G) par vitesse consigne et par glissement consigne	67
38	Distribution des observations gardées du contaminant N.C. (G) par vitesse consigne et par glissement consigne	68
39	Distribution des observations gardées du contaminant N.C. (B) par vitesse consigne et par glissement consigne	69
40	Distribution des observations gardées du contaminant verglas par vitesse consigne et par glissement consigne	70
41	Régression par morceau pour le contaminant Neige fraiche (G), avec $\lambda_1 =$ 0.0001 , $\lambda_2 = 0.003$, $\lambda_3 = 0$, $\lambda_4 = 0.0001$	71
42	Régression par morceau pour le contaminant N.C. (G), avec $\lambda_1 = 0.0001$, $\lambda_2 = 0$, $\lambda_3 = 0$, $\lambda_4 = 0.0005$,	72
43	Régression par morceau pour le contaminant N.C. (B), avec $\lambda_1 = 0.05$, $\lambda_2 = 0.0025$, $\lambda_3 = 0$, $\lambda_4 = 0.0002$	72
44	Régression par morceau pour le contaminant Verglas, avec $\lambda_1 = 0.005$, $\lambda_2 = 0.002$, $\lambda_3 = 0.01$, $\lambda_4 = 0.0005$,	73

Liste des tableaux

1	Exemple de matrice de confusion pour K classes.	37
2	Modification de la valeur maximale du CFL C en passant de 65 km/h à 40 km/h	49
3	Résultats des tests R^2 pour XGBoost et Random Forest	50
4	Probabilités d'appartenance aux différentes classes pour chaque sous-intervalle de CFL C, ainsi que les classes prédites et réelles.	55
5	Probabilités d'appartenance aux différentes classes pour chaque intervalle de CFL C, ainsi que les classes prédites et réelles.	61
6	Probabilités d'appartenance aux différentes classes pour chaque intervalle de CFL C, ainsi que les classes prédites et réelles.	63
7	Hyperparamètres optimisés pour Random Forest Regressor	73
8	Hyperparamètres optimisés pour XGBoost Regressor	74

Liste des Abréviations

CFL	Coefficient de Frottement Longitudinal
GRF	Global Reporting Format
IMAG	Instrument de mesure automatique de glissance
N.C. (B)	Neige compactée sur béton
NC.C	Neige compactée compactée
N.C. (G)	Neige compactée sur glace
Neige fraîche (B)	Neige fraîche sur béton
Neige fraîche (G)	Neige fraîche sur glace
RCAM	Runway condition assessment matrix (matrice d'évaluation d'état de surface)

Introduction

Les accidents d’avion, bien que rares, font l’objet d’une forte médiatisation en raison de leur nature tragique et du grand nombre de vies qu’ils peuvent coûter. Pourtant, l’avion reste le moyen de transport le plus sûr. Les phases d’atterrissage et de décollage sont les plus critiques, rendant l’adhérence des pistes essentielle, qu’elles soient sèches, mouillées ou couvertes de contaminants moins fréquents comme la neige, la glace ou le verglas.

L’adhérence correspond aux forces qui agissent entre deux surfaces en contact rapproché, les empêchant de glisser l’une contre l’autre. Pour évaluer l’adhérence d’un véhicule, on utilise le coefficient de frottement longitudinal (CFL), un nombre adimensionnel compris entre 0 et 1, où 0 représente une surface extrêmement glissante et 1 une adhérence maximale. Le CFL est une mesure cruciale pour les gestionnaires d’aéroports et les organismes comme la DGAC, permettant de déterminer l’état d’adhérence d’une piste. Ce coefficient peut être influencé par des contaminants externes, comme l’usure de la chaussée ou les résidus de gomme, ainsi que par des conditions météorologiques telles que la pluie ou la neige.

La sécurité des vols dépend largement de la l’état de surface des pistes. Pour chaque atterrissage ou décollage, les pilotes ont besoin d’une description claire et fiable de l’état de la piste. L’adhérence est l’un des facteurs essentiels influant la sécurité des mouvements d’avion au sol, aux côtés de la présence de contaminants météorologiques. Elle peut être affectée par ceux-ci mais aussi par des caractéristiques intrinsèques de la piste, comme les matériaux utilisés et les méthodes de construction, ou par la température de la surface.

Bien que l’adhérence sur les surfaces sèches ou mouillées soit bien comprise et modélisée, permettant une évaluation fiable, des études paramétriques restent nécessaires pour affiner cette compréhension. En revanche, l’adhérence sur les surfaces hivernales est moins bien comprise. La modélisation de ces phénomènes, limitée par la rareté des données et la faible occurrence de telles conditions, n’a pas encore permis de développer une vue d’ensemble satisfaisante de l’impact de ces contaminants.

Ce rapport s’articule ainsi autour de la modélisation de l’impact des contaminants hivernaux sur l’adhérence opérationnelle.

Dans un premier temps, une étude de la validité des mesures réalisées lors de la campagne organisée par le STAC sur l’aéroport de Montréal Miribel en janvier 2024 sera réalisée, suivie d’une analyse de la qualité de la base de données à travers l’examen de la reproductibilité et de la répétabilité des résultats. Ensuite, la modélisation du CFL sera effectuée en utilisant des variables explicatives telles que le glissement moyen et la vitesse, d’abord à l’aide d’un modèle de régression pénalisé par morceaux, puis par une modélisation ensembliste. Par la suite, une étude inverse sera menée pour classer les contaminants en fonction de la valeur du CFL et de son interaction avec le glissement et la vitesse.

1 Contexte de l'étude

Cette section vise à introduire le contexte du projet et à fournir une description détaillée des variables utilisées dans notre étude, en précisant leur origine et leur nature.

1.1 Présentation de l'expérimentation

En janvier 2024, la division Sécurité Adhérence des Pistes, en collaboration avec le laboratoire d'essai et d'expertise, a mené une campagne de mesures d'adhérence opérationnelle sur l'aéroport de Montréal Mirabel au Canada. Cette initiative, intégrée aux programmes de recherche sur la « modélisation des performances de freinage avion sur chaussée contaminée hivernale », vise à mieux comprendre le comportement des machines de mesure d'adhérence sur piste contaminée et à mieux évaluer les performances de freinage des avions sur ces mêmes pistes.

L'aéroport de Mirabel est situé au Nord-Ouest de Montréal, avec la particularité d'être devenu uniquement un aéroport de fret. La piste choisie est la 11/29, en partant du seuil 29 sur une distance d'au moins 1000 mètres.




FIGURE 1 – L'aéroport de Mirabel

L'objectif principal est de caractériser de manière exhaustive l'adhérence relative à tout tribosystème en faisant varier la vitesse et le taux de freinage, sur un ou plusieurs contaminants types et représentatifs du Global Reporting Format qui a standardisé au niveau mondial les méthodes d'évaluation et de communication de l'état de surface des pistes. Cette campagne permettra de calibrer puis valider la modélisation du contact pneu/chaussée pour prédire la performance réelle de l'avion.

Les contaminants sélectionnés pour l'étude incluent le **slush** (terme anglais désignant un mélange d'eau et de neige fondante dans des proportions indéterminées), la **neige compactée**, la **neige mouillée**, le **verglas**, et la **neige fraîche**.

Ces essais se sont déroulés sur une période de 5 jours ouvrés, permettant ainsi de réaliser des répétitions et d'ajuster les conditions en fonction du type de contamination.



(a) Plan de piste mission Mirabel



(b) IMAG sur neige



(c) IMAG sur glace

FIGURE 2 – Illustrations de la mission Mirabel

1.2 Pourquoi modéliser le CFL

Le coefficient de frottement longitudinal (CFL) est le rapport entre la force de frottement ralentissant le pneumatique et la force verticale appliquée à la roue. Il peut être comparé au coefficient de frottement de Coulomb, qui décrit la résistance au glissement entre deux surfaces en contact.

L'adhérence des pneumatiques d'un avion à la piste est cruciale pour plusieurs raisons :

1. **Freinage à l'atterrissage** : Une bonne adhérence permet de réduire la distance de freinage et d'assurer un arrêt en toute sécurité.
2. **Décollage avorté** : En cas de besoin d'interrompre un décollage, une adhérence adéquate assure que l'avion puisse s'arrêter avant la fin de la piste.
3. **Optimisation** : optimisation des propriétés drainantes des chaussées aéronautiques.
4. **Phase de taxiage** : Une bonne adhérence est nécessaire pour maintenir le contrôle

de la direction de l'avion pendant le roulage, surtout dans des conditions de piste contaminée ou glissante.

La mesure la plus précise pour évaluer l'adhérence des avions sur une chaussée dans des conditions spécifiques est celle du coefficient de frottement longitudinal (CFL). Cette mesure est réalisée à travers des essais rigoureux, où divers points de fonctionnement sont testés en faisant varier la vitesse et le taux de freinage.




FIGURE 3 – Coefficient de frottement longitudinal (source : [1])

Pour chaque passage (avec la même valeur de vitesse consigne, de glissement consigne et pour le même contaminant), le trajet est divisé en partitions de 20 mètres. Pour chaque mètre de chaque partition, le coefficient de frottement longitudinal (CFL) est mesuré. À la fin de chaque portion, les valeurs moyennes et les écarts types du CFL, ainsi que de la vitesse, du glissement et de la masse sont calculés. La stabilité des moyennes du CFL, du glissement et de la masse également, sont mesurés, en tenant compte du fait que la mesure est effectuée avec une seule machine appliquant une masse de 180 kg. Les différents contaminants provoquent des secousses du véhicule, ce qui entraîne une variabilité de la masse, qui doit être centrée sur 180 kg.

1.3 Description des variables

La base de données initiale comprend 31 variables et 2236 observations. Ces variables se répartissent en plusieurs catégories :

1. Variables liées au moyen de mesure :

- Machine de mesure : IMAG 208 G 117
- Nature du pneumatique : Pneu rainuré PEX Mt St Dauphin

2. Informations sur la piste de mesure :

- Nom de curseur : Identifiant de la section de piste, la section numéro i est nommée C_m (avec $m = 20 \times (i - 1)$)
- Seuil de départ : Indique le côté de début de mesure
- Position par rapport à l'axe : Indique si la mesure est effectuée à droite ou à gauche de l'axe de la piste
- Intervalles de chaque passage : Distance minimale et maximale en mètres pour chaque passage, pour un curseur C_{100} où pas min = 100, et pas max = 120

3. Variables temporelles :

— Date et heure exacte de mesure

4. Variables de mesure :

- Vitesse : les valeurs sont centrées sur 40 km/h ou 65 km/h
- Moyenne du glissement : prend des valeurs entre 0% et 100%
- Masse du véhicule pour chaque observation
- Température de surface : étant donné qu'on travaille en conditions hivernales, les températures sont négatives (entre -24 et -11 degrés C)
- Température de bande de roulement : les températures varient de -1 à 13 degrés C
- Nature du contaminant et sa hauteur (en mm) : L'ensemble de ces contaminants sont ceux pouvant être retrouvés sur un aéroport en conditions opérationnelles tel qu'ils figurent dans la RCAM relative au GRF, il y a 9 types de contaminant : Neige fraîche (B) (30 mm), Neige fraîche (G) (30 mm), N.C. (G) (16 mm), N.C. (B) (16 mm), NC.C. 16 mm), Verglas (0 mm), Glace (0 mm), SLUSH (15 mm)

5. Variables de frottement :

- Coefficient de frottement longitudinal (CFL C) : Mesure de la force de frottement par le biais du couple mesuré au centre de la roue
- Force de frottement (CFL F) : Mesure de la force de freinage s'appliquant sur la roue. Il s'agit de la somme de la force de frottement et de trainée, elle-même engendrée par le cumul du contaminant à l'avant de la roue.

6. Mesures de stabilité

En outre, des mesures de stabilité (écart type et incertitude) ont été effectuées pour les valeurs suivantes :

- CFL C
- CFL F
- Glissement
- Masse

Ces mesures de stabilité sont essentielles pour garantir la répétabilité et la reproductibilité des essais, (aspects qui seront détaillés dans la suite de ce rapport). Elles permettent surtout de s'assurer de la bonne réalisation d'une mesure d'adhérence et de l'homogénéisation du coefficient mesuré.

Calcul de l'incertitude

L'incertitude est calculée en se basant sur l'hypothèse que chaque mesure (pour les variables citées ci-dessus) est indépendante et suit une distribution normale centrée sur une valeur moyenne avec un écart type inconnu. Cette hypothèse permet de construire un intervalle de confiance sous la forme suivante :

Pour chercher l'intervalle de confiance de niveau $1 - \alpha$ pour la moyenne μ lorsque l'écart type σ est inconnu, σ^2 est estimé par la variance empirique corrigée :

$$V_n = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$

et on pose :

$$S = \sqrt{V_n}$$

D'après le théorème de Student,

$$T = \sqrt{n} \frac{\bar{X}_n - \mu}{S}$$

suit une loi de Student à $n - 1$ degrés de liberté.

On considère le quantile $t_{1-\alpha/2}^{n-1}$ d'ordre $1 - \alpha/2$ de la loi de Student à $n - 1$ degrés de liberté. Ainsi, la probabilité d'avoir l'encadrement

$$-t_{1-\alpha/2}^{n-1} \leq T \leq t_{1-\alpha/2}^{n-1}$$

est $1 - \alpha$.

En réécrivant l'encadrement, on a une probabilité de $1 - \alpha$ d'avoir :

$$\bar{X}_n - t_{1-\alpha/2}^{n-1} \frac{S}{\sqrt{n}} < \mu < \bar{X}_n + t_{1-\alpha/2}^{n-1} \frac{S}{\sqrt{n}}$$

L'intervalle de confiance de niveau $1 - \alpha$ est donc :

$$\left[\bar{X}_n - t_{1-\alpha/2}^{n-1} \frac{S}{\sqrt{n}}, \bar{X}_n + t_{1-\alpha/2}^{n-1} \frac{S}{\sqrt{n}} \right]$$

Dans notre étude, on appelle incertitude la valeur :

$$t_{1-\alpha/2}^{n-1} \frac{S}{\sqrt{n}}$$

Dans ce cas, la constante est le quantile de Student à $(21 - 1)$ degrés de liberté d'ordre $1 - \alpha/2$ (pour un taux d'erreur de $\alpha = 5\%$), dont la valeur est 2.086, avec $n = 21$.

Interprétation

Si l'intervalle de confiance est calculé pour un niveau de confiance de 95% (donc $\alpha = 0.05$), cela signifie que :

- **Interprétation statistique :** Il y a 95% de chances que cet intervalle contienne la vraie valeur moyenne μ du coefficient de frottement longitudinal pour le contaminant donné.
- **Confiance dans les mesures :** Les bornes de l'intervalle indiquent la précision de notre estimation. Un intervalle plus étroit signifie que nous avons une estimation plus précise de la moyenne, tandis qu'un intervalle plus large indique une plus grande incertitude.
- **Application pratique :** En pratique, cet intervalle permet de prendre des décisions informées sur la sécurité et la performance des avions sur des pistes contaminées. Par exemple, si les valeurs de CFL C dans cet intervalle sont acceptables selon les normes de sécurité, on peut conclure que la piste est sûre pour les opérations aériennes sous les conditions de contaminant spécifiées.

Exemple concret

Supposons que nous avons calculé une moyenne $\bar{X}_n = 0.4$ et un écart type $S = 0.05$ à partir de $n = 21$ observations. Avec $t_{0.975}^{21} = 2.086$, l'intervalle de confiance à 95% est :

$$\begin{aligned} & \left[0.4 - 2.086 \times \frac{0.05}{\sqrt{20}}, 0.4 + 2.086 \times \frac{0.05}{\sqrt{20}} \right] \\ & [0.4 - 0.0234, 0.4 + 0.0234] \end{aligned}$$

$$[0.3766, 0.4234]$$

Cela signifie qu'avec 95% de confiance, la vraie valeur moyenne de X se situe entre 0.3766 et 0.4234.

En utilisant cet intervalle de confiance, on peut évaluer la fiabilité des mesures obtenues et s'assurer que les décisions prises sur la base de ces mesures sont bien fondées et statistiquement justifiées. Ces analyses sont essentielles pour garantir l'homogénéisation d'une mesure et sa stabilité ainsi que la répétabilité et la reproductibilité des essais, assurant ainsi des opérations aériennes sécurisées.

2 Préparation de la table de données

Dans un projet de data science la préparation des données est crucial pour assurer la fiabilité des résultats.

En éliminant les erreurs, les valeurs aberrantes et en gérant les données manquantes, on garantit la qualité des données utilisées pour l'analyse. Ce processus permet également de préparer les données en vue de la modélisation, en assurant une cohérence et une précision optimales.

2.1 Nettoyage des données

Certaines valeurs de CFL C sont négatives (une valeur très petite tendant vers 0). Dans ce cas, ces valeurs seront transformées en 0, puisque les valeurs de CFL C doivent être comprises entre 0 et 1. De plus, les valeurs manquantes seront supprimées de la base de données. Dans la base de données initiale, 103 valeurs étaient manquantes pour la variable "contaminant". Après avoir supprimé toutes les valeurs manquantes, le jeu de données final comporte 2133 observations. Cela correspond à la taille initiale du jeu de données diminuée de 103.

2.2 Validation des observations

Avant de faire une analyse exploratoire de toute notre base de données, il faut tout d'abord définir un critère de validité des observations, c'est-à-dire supprimer les observations ayant une valeur moyenne de glissement ou de masse qui est instable (pour la variable cible, on va la traiter après).

2.2.1 Importance de définir un critère de stabilité

Définir un critère de stabilité est essentiel pour garantir la fiabilité des mesures et des analyses. Comme on peut le voir dans l'exemple suivant, illustré par l'image ci-dessous, les petites valeurs de glissement peuvent entraîner de fortes variations dans le coefficient de frottement longitudinal (CFL).

Exemple illustratif

Pour le contaminant "glace", sur une section de 20 mètres :

- Glissement moyen : 3%
- Incertitude : 1.5%
- Variation du CFL : de 0 à 0.2 (pour mémoire, le CFL varie au maximum entre 0 et 1)

Ces valeurs montrent une grande dispersion, ce qui signifie que les mesures de CFL pour ces petites valeurs de glissement sont peu fiables et doivent être invalidées.

En revanche, pour une valeur de glissement de 60% avec une incertitude de 10% :

- Variation du CFL : de 0.14 à 0.16

Ici, même une grande variation dans le glissement entraîne une variation non significative du CFL, indiquant des mesures plus stables et fiables.




FIGURE 4 – Aspect de la courbe du CFL en fonction du glissement par quelque contaminant (source : [2])

Critère de stabilité de glissement

Pour ces raisons, il est crucial de déterminer un critère de stabilité plus strict pour les petites valeurs de glissement par rapport aux grandes valeurs. Le seuil de validation doit être adapté en fonction de la valeur de glissement afin de s'assurer que les mesures de CFL soient fiables et représentatives des conditions réelles.

Incertitude de la masse

Pour la masse, il est toléré de prendre une valeur d'incertitude dépassant 15 kg. Cette tolérance est acceptable car l'incertitude de la masse n'a pas d'impact significatif sur le coefficient de frottement longitudinal (CFL C).

Centrage de la masse

Il est également exigé que la moyenne des masses soit centrée sur 180 kg, garantissant ainsi une uniformité dans les conditions de test (il s'agit du point de fonctionnement propre à l'IMAG).

La détermination de ces seuils nous permet d'avoir :

1. **La précision des mesures** : Assurer que les mesures du coefficient de frottement longitudinal (CFL) soient cohérentes et précises
2. **L'adaptabilité** : Permettre une adaptation flexible aux différentes conditions rencontrées sur les pistes contaminées
3. **La fiabilité des analyses** : Garantir une analyse reposant sur des données robustes, maîtrisées et représentatives des conditions opérationnelles optimales en matière d'adhérence

2.2.2 Critère de stabilité et définition des seuils

Pour garantir des mesures fiables et représentatives, il est essentiel de définir des seuils spécifiques de stabilité pour chaque contaminant et pour chaque intervalle de valeur du glissement.

Pour choisir un seuil, il faut vérifier certaines conditions :

Adaptation au contaminant : Chaque type de contaminant (par exemple, neige, glace, etc.) a des caractéristiques différentes qui influencent l’asservissement de la machine, notamment la force verticale et le taux de freinage (G%). Par conséquent, les seuils de stabilité doivent être adaptés en fonction du contaminant testé.

Intervalle de valeur du glissement : Les seuils de stabilité doivent également varier en fonction des intervalles de valeur du glissement. Pour les petites valeurs, des seuils plus stricts sont nécessaires pour garantir la précision des mesures. Pour les grandes valeurs, une tolérance plus grande peut être acceptée.

Validation par un physicien : L’objectif est de trouver un compromis entre la quantité et la qualité des données, en privilégiant la qualité. Le choix de la discrétisation des intervalles de glissement et des seuils est déterminé par des outils statistiques (analyse des distributions, étude des dispersions, effets marginaux, etc.). Mais, tous ces choix doivent être validés par un expert comprenant les mécanismes physiques de l’adhérence afin de préserver la pertinence et la cohérence du travail, sous peine de devoir être repris

Si l’un des critères suivants est rempli :

- La marge de l’intervalle de confiance du pourcentage de glissement ($IC_{g\%}$) dépasse le seuil seuil_g
- L’intervalle de confiance de la force verticale (IC_{Fv}) dépasse le seuil seuil_{Fv}
- La différence absolue entre 180 kg et la force verticale ($|180 - Fv|$) dépasse le seuil seuil_{180}

Alors, l’observation est refusée. Sinon, l’observation est validée.

Dans ce qui suit, trois variables contenant chacune un critère seront examinées.

2.3 Détermination des choix des seuils de chaque contaminant

Dans cette partie, les critères de validation de certains contaminants ainsi qu’une synthèse des observations retenues seront présentés. Les critères de validation sont présentés pour Neige fraîche (B), NC.C., Glace et Slush. Pour les autres contaminants, les informations seront disponibles dans la première partie de l’annexe.

2.3.1 Validation des observations en présence des contaminants

Neige fraîche (B)

Pour le contaminant Neige fraîche (B), représentant 337 observations dans la base de données initiale, les seuils de validation du glissement sont définis en fonction de la moyenne du pourcentage de glissement (G%).

Critères de Validation du Glissement :

$$\text{Seuil} = \begin{cases} 0.5 & \text{si } G\% < 3 \\ 0.8 & \text{si } G\% < 10 \\ 1.4 & \text{si } 10 \leq G\% \leq 20 \\ 5 & \text{si } G\% > 20 \end{cases}$$

Autres Critères de Validation

$$\begin{cases} \text{Deuxième critère} & : & \text{Seuil} = 16 \\ \text{Troisième critère} & : & \text{Seuil} = 5 \end{cases}$$

Résultats de l'Application des Seuils

En appliquant ces seuils, sur 337 observations initiales pour le contaminant Neige fraîche (B), 141 ont été supprimées. Ce type de contaminant hivernal s'avère donc très hétérogène et a rendu difficile l'obtention de mesures suffisamment stables et fiables.




FIGURE 5 – Distribution des observations gardées du contaminant Neige fraîche (B) par vitesse consigne (km/h) et par glissement consigne (%)

NC.C.

Pour le contaminant NC.C., représentant 540 observations dans la base de données initiale, les seuils de validation du glissement sont définis en fonction de la moyenne du pourcentage de glissement ($G\%$).

Critères de Validation du Glissement :

$$\text{Seuil} = \begin{cases} 0.4 & \text{si } G\% < 3 \\ 0.8 & \text{si } G\% < 10 \\ 1.5 & \text{si } 10 \leq G\% \leq 20 \\ 5 & \text{si } G\% > 20 \end{cases}$$

Autres Critères de Validation

$$\begin{cases} \text{Deuxième critère} & : \text{Seuil} = 16 \\ \text{Troisième critère} & : \text{Seuil} = 5 \end{cases}$$

Résultats de l'Application des Seuils

En appliquant ces seuils, sur 540 observations initiales du contaminant NC.C., 288 ont été supprimées. Là encore, ce contaminant s'est avéré assez hétérogène pour impacter la qualité des mesures par l'IMAG.




FIGURE 6 – Distribution des observations gardées du contaminant NC.C. par vitesse consigne et par glissement consigne

Glace

Pour le troisième contaminant, Glace, représentant 180 observations dans la base de données initiale, les seuils de validation du glissement sont définis en fonction de la moyenne du pourcentage de glissement ($G\%$).

Critères de Validation du Glissement :

$$\text{Seuil} = \begin{cases} 0.6 & \text{si } G\% < 10 \\ 1.5 & \text{si } 10 \leq G\% \leq 20 \\ 5 & \text{si } G\% > 20 \end{cases}$$

Par exemple, avec une moyenne de glissement de 7%, seules les valeurs comprises entre 6,4% et 7,6% seront considérées comme valides. Pour une moyenne de glissement de 18,5%, les valeurs acceptées seront comprises entre 17% et 20%. Enfin, avec une moyenne de glissement de 80%, les valeurs comprises entre 75% et 85% seront acceptées.

Autres Critères de Validation

$$\begin{cases} \text{Deuxième critère} & : \text{Seuil} = 15 \\ \text{Troisième critère} & : \text{Seuil} = 5 \end{cases}$$

Par exemple, lorsque la masse est centrée sur 180 kg, les observations entre 165 kg et 195 kg seront validées pour le deuxième critère. Pour le troisième critère, les valeurs de moyenne des masses comprises entre 175 kg et 185 kg seront tolérées.

Résultats de l'Application des Seuils

Après application de ces seuils, 49 des 180 observations initiales ont été supprimées pour le contaminant Glace. Contrairement aux contaminants précédents, la glace présente sur la piste s'est avérée assez homogène pour permettre un bon taux de conservation des observations.




FIGURE 7 – Distribution des observations gardées du contaminant Glace par vitesse consigne et par glissement consigne

Slush

Pour le deuxième contaminant, Slush, représentant 168 observations dans la base de données initiale, les seuils de validation du glissement sont définis en fonction de la moyenne du pourcentage de glissement ($G\%$).

Critères de Validation du Glissement :

$$\text{Seuil} = \begin{cases} 0.5 & \text{si } G\% < 3 \\ 1.35 & \text{si } G\% < 10 \\ 1.9 & \text{si } 10 \leq G\% \leq 20 \\ 5 & \text{si } G\% > 20 \end{cases}$$

Par exemple, avec une moyenne de glissement de 2,5%, seules les valeurs comprises entre 2% et 3% seront considérées comme valides. Pour une moyenne de glissement de 8%,

seules les valeurs entre 6,65% et 9,35% seront valides. Avec une moyenne de glissement de 15%, les valeurs acceptées seront comprises entre 13,1% et 16,9%. Enfin, pour une moyenne de glissement de 80%, les valeurs comprises entre 75% et 85% seront acceptées.

Autres Critères de Validation

Physiquement, on accepte des seuils plus larges, car le slush provoque des secousses qui perturbent le système avec des variations verticales plus importantes, contrairement aux autres contaminants plus lisses.

$$\begin{cases} \text{Deuxième critère} & : \text{Seuil} = 28.5 \\ \text{Troisième critère} & : \text{Seuil} = 6 \end{cases}$$

Par exemple, lorsque la masse est centrée sur 180 kg, les observations entre 151,5 kg et 208,5 kg seront validées pour le deuxième critère. Pour le troisième critère, les valeurs de moyenne des masses comprises entre 174 kg et 186 kg seront tolérées.

Résultats de l'Application des Seuils

Après application de ces seuils, 83 des 186 observations initiales ont été supprimées pour le contaminant Slush.




FIGURE 8 – Distribution des observations gardées du contaminant Slush par vitesse consigne et par glissement consigne

2.3.2 Synthèse des observations retenues

Après avoir filtré notre base de données, nous gardons finalement :

- 60 le nombre des données gardées pour le contaminant Verglas
- 85 le nombre des données gardées pour le contaminant Slush
- 131 le nombre des données gardées pour le contaminant Glace
- 123 le nombre des données gardées pour le contaminant N.C. (G)
- 148 le nombre des données gardées pour le contaminant N.C. (B)
- 252 le nombre des données gardées pour le contaminant NC.C.
- 196 le nombre des données gardées pour le contaminant Neige fraîche (B)
- 132 le nombre des données gardées pour le contaminant Neige fraîche (G)

C'est-à-dire un nombre total de données validées de 1127. Valider 1127 observations (54% des observations du jeu de données initial) signifie un refus de 958 observations (46% des observations du jeu de données initial), ce qui constitue à peu près la moitié de notre base de données initiale. Mais comme toujours : *"La qualité de la base de données est plus importante que sa quantité."*

2.4 Étude de la reproductibilité et la répétabilité

Après l'application de ces seuils, 1146 observations ont été acceptées et 987 rejetées. En d'autres termes, 54% des observations de notre jeu de données ont été validées. Ainsi, nous avons amélioré la qualité de notre base de données malgré une réduction de sa quantité.

2.4.1 Définitions et remarques

Un **passage** est défini par un contaminant donné, une vitesse consigne donnée, un glissement consigne donné et une heure donnée. C'est-à-dire les valeurs que l'on obtient lors des mesures effectuées pour un contaminant, pour une vitesse consigne, pour un taux de freinage consigne pendant un temps exact, vu qu'un contaminant est mesuré seulement dans une journée. Cela signifie que pour deux dates différentes, on n'aura pas des mesures du même contaminant (mais dans un seul jour, on peut mesurer plus qu'un contaminant). Pour la date exacte, on va se contenter de l'heure.

La **reproductibilité** s'apparente ici à l'homogénéisation du contaminant dans le sens longitudinal. Cela nous permet de vérifier que les 7 pas de 20 mètres sont semblant et traduisent le même contaminant. Pour garantir la **reproductibilité**, il est nécessaire que les valeurs du CFL C pour chaque **passage** soient homogènes (les valeurs de chaque segment de 20 mètres doivent être homogènes). Statistiquement parlant, cela signifie que l'écart-type de ces valeurs doit être faible.

Pour garantir la **répétabilité**, il est nécessaire que les valeurs du CFL C pour tous les **passages** ayant les mêmes caractéristiques, c'est-à-dire la même vitesse et glissement consigne, soient homogènes (les valeurs du CFL C de chaque **passage** doivent être cohérentes). Statistiquement parlant, cela signifie que l'écart-type de ces valeurs doit être faible. La **répétabilité** est ici employée pour s'assurer que la machine est stable durant la totalité des essais en terme de mesures établies.

Cette étude est importante pour évaluer la qualité des données et la stabilité des mesures. L'objectif final est d'optimiser la performance du modèle de prédiction final, qu'il s'agisse de classification ou de régression.

Pour juger si un écart type est faible ou non, nous allons définir des seuils pour les valeurs de CFL C pour tous les contaminants. Si l'écart type est inférieur à ce seuil, on dit que la valeur de CFL C est faible; sinon, on juge que la valeur moyenne du (ou des) passages n'est pas fiable. Il est alors nécessaire de chercher dans ces distributions pour supprimer les valeurs aberrantes (une valeur aberrante signifie une valeur extrême par rapport à la distribution de chaque distribution, ou bien une valeur éminemment observable qu'il s'agit d'une erreur de mesure; par exemple, un taux de freinage de 1% pour une vitesse de 65 km/h sur le contaminant "Glace" renvoie un résultat de 0,4 pour

le CFL C. On rappelle que le CFL C est compris entre 0 et 1). Les valeurs des seuils doivent être croissantes avec la valeur moyenne du CFL C du (ou des) passages.

Les seuils choisis sont les suivants :

$$S_{\sigma} = \begin{cases} 0,01 & \text{si CFL C} \leq 0,03 \\ 0,02 & \text{si } 0,03 < \text{si CFL C} \leq 0,1 \\ 0,03 & \text{si CFL C} > 0,1 \end{cases}$$

Cela signifie que, par exemple, une moyenne de CFL C de 0,02 avec un écart type de 0,015 sera refusée.

Des recommandations puis une validation par un physicien était obligatoire pour le choix des seuils avant de passer à l'étude de la reproductibilité et de la répétabilité.

Remarque 1 :

Pour la variable "Moyenne CFL C" de la base de données initiale, ces valeurs sont les moyennes des CFL C, mesurées sur chaque mètre du segment de 20 mètres (même chose pour les autres variables : vitesse moyenne, glissement moyen, Fv). Pour la reproductibilité, la moyenne du CFL C est la moyenne des moyennes des CFL C sur un passage. Pour la répétabilité, lorsqu'on parle de la moyenne du CFL C, on parle de la moyenne des moyennes du CFL C pour tous les passages ayant les mêmes caractéristiques (même glissement et vitesse consigne).

Remarque 2 :

Pourquoi pour l'étude de la stabilité du glissement et de la masse, avons-nous comparé les seuils avec les incertitudes, alors que pour le CFL C, nous les avons comparés avec l'écart-type des distributions des moyennes de CFL C ?

Avant de construire les intervalles de confiance des valeurs de glissement et de masse, nous avons fait une hypothèse essentielle pour la suite du raisonnement : nous avons supposé que les variables suivent une loi gaussienne. Cette hypothèse permet de construire des intervalles de confiance et est convenable en l'occurrence, car nous avons un nombre d'observations non négligeable, de 20. De plus, nous nous attendions d'après les valeurs consignées à ce que les variables soient centrées sur elles. Toutefois, pour l'étude de la reproductibilité ou de la répétabilité, parfois dans un passage nous n'avons que deux ou trois valeurs de CFL C. De plus, cette variable est la variable à expliquer, c'est-à-dire que nous n'avons pas de valeur consigne. Finalement, l'hypothèse de normalité n'aurait aucun sens, tout comme les intervalles de confiance et les incertitudes.

Remarque 3 :

Nous avons défini chaque passage par l'ensemble des mesures pour un contaminant, un glissement consigne, une vitesse consigne et une date précise. En général, les valeurs du glissement moyen sont centrées sur le glissement consigne. Cependant, pour atteindre un glissement consigne, il peut y avoir une phase de transition qui produit des valeurs légèrement éloignées du glissement consigne. Ces valeurs sont toujours considérées comme des observations du glissement consigne, même si elles en sont éloignées. Par conséquent, on peut recevoir une valeur de CFL C également éloignée de celles données par les glissements centrés sur le glissement consigne. (On n'a pas ce problème entre la vitesse moyenne

et la vitesse consigne, car nous avons des pistes d'accélération et de décélération, ce qui pousse les vitesses moyennes à être centrées sur les variables consignes.)

La valeur reçue de CFL C dans ce cas n'est pas considérée comme une erreur de mesure, c'est-à-dire qu'il s'agit bien d'une valeur réelle. Toutefois, elle peut biaiser l'écart type des moyennes de CFL C au sein du même passage. Dans ce cas, nous avons décidé de supprimer ces valeurs de l'étude de la reproductibilité et de la répétabilité, mais nous les réintégrerons à l'étape de la modélisation.

2.4.2 Étude de la reproductibilité

Pour étudier la reproductibilité, nous avons créé un tableau qui regroupe la valeur moyenne par passage du CFL C, ainsi que l'écart type et le seuil pour les variables contaminant, vitesse consigne, glissement consigne et l'heure de mesure. Le tableau contient 207 lignes, La forme du tableau est la suivante :

				mean	std	Seuil
Contaminant	Vitesse	Glissement	Heure			
N.C. (G)	40	2	14:44:15	0.035952	0.003316	0.01
			16:22:36	0.042042	0.014369	0.01
			16:27:31	0.045214	0.006431	0.01
			16:31:01	0.022333	0.004781	0.01
		4	14:48:06	0.132607	0.028663	0.01
			16:37:44	0.126214	0.014074	0.01
		7	14:51:31	0.164163	0.006628	0.01
			16:40:54	0.203738	0.014647	0.01
			16:55:43	0.186117	0.011143	0.01
		11	16:44:08	0.216929	0.018846	0.01
		15	16:48:25	0.235581	0.007161	0.01
			16:59:11	0.230210	0.020523	0.01
100		16:51:39	0.139313	0.009482	0.01	

FIGURE 9 – forme du tableau des valeurs moyennes, écarts types et seuils par contaminant, vitesse consigne, glissement consigne et heure de mesure

Il est important de noter que, compte tenu du grand nombre de groupes, visualiser les écarts-types dans un graphique est une très mauvaise idée. Cela entraînerait un graphique très chaotique, comme celui ci-dessous.




FIGURE 10 – Écart type des moyennes du CFL C de chaque passage, à 40 km/h

La figure nous donne une idée sur les valeurs des écarts types, ce qui nous aide à conclure que les écarts types prennent des valeurs faibles, et donc le problème tend vers une bonne reproductibilité. Cependant, nous ne pouvons pas détecter quels sont les passages qui dépassent leur seuil, et nous ne pouvons pas voir clairement les couleurs qui représentent chacune d’elles une valeur de glissement pour une heure donnée.

C’est pourquoi, pour analyser les valeurs des écarts types, nous allons examiner directement la table des ecarts types qui dépassent leur seuil. Le tableau contenant les valeurs des écarts types dépassant les seuils a **28 lignes**. La prochaine étape consiste à identifier la source de ce problème et à le résoudre. Chaque ligne de ce tableau présente un passage qui donne plusieurs valeurs de CFL C. En tenant compte de la remarque 3, nous avons supprimé deux observations de la base de données initiale pour le contaminant Glace, 9 valeurs du contaminant NCG, 5 valeurs du contaminant NCC, 3 observations du contaminant Neige fraîche (G), et 3 observations de Slush.

2.4.3 Étude de la répétabilité

Pour étudier la répétabilité, nous avons créé un tableau qui regroupe la valeur moyenne des passages du CFL C, ainsi que l'écart type et le seuil par les variables contaminant, vitesse consigne et glissement consigne. Le tableau contient 103 lignes, La forme du tableau est la suivante :

			mean	std
Contaminant	Vitesse	Glissement		
Glace	40	2	0.005942	0.003678
		4	0.006858	0.007036
		7	0.043000	0.015700
		11	0.073051	0.015939
		15	0.092032	0.023087
		100	0.072402	0.016639
	65	2	0.024625	0.004611
		4	0.038392	0.012699
		7	0.075662	0.025510
		11	0.095108	0.015176
		15	0.095070	0.011792
		100	0.073727	0.019572

FIGURE 11 – forme du tableau des valeurs moyennes, écarts types et seuils par contaminant, vitesse consigne et glissement consigne

Nous allons maintenant visualiser ce tableau pour avoir une idée des valeurs des écarts types pour chaque groupe.

On peut voir dans les deux graphiques ci-dessus que les valeurs des écarts types des moyennes CFL C des groupes tendent vers une bonne répétabilité. Nous allons maintenant examiner directement la table des écarts types qui dépassent leur seuil.




FIGURE 12 – Écart type des moyennes du CFL C de chaque groupe, à 40 km/h




FIGURE 13 – Écart type des moyennes du CFL C de chaque groupe, à 65 km/h

Le tableau contenant les valeurs des écarts types dépassant les seuils a 26 lignes. La prochaine étape consiste à identifier la source de ce problème et à le résoudre. Chaque ligne de ce tableau présente un groupe de passages qui donne plusieurs valeurs de CFL C. En tenant compte de la remarque 3, nous avons supprimé 8 observations du contaminant NCB, 21 observations de Slush, 13 observations du NCG, 17 observations du contaminant NCC, 16 observations du contaminant Glace, 5 observations du contaminant Neige fraiche (B) et deux observations du contaminant Verglas.

Finalement, nous avons supprimé 105 observations de notre base de données initiales. Après avoir revérifié les écarts types, nous constatons qu'ils sont bien inférieurs aux seuils, ce qui prouve que nous travaillons dans des bonnes conditions de reproductibilité et de répétabilité. Ainsi, d'un point de vue statistique, nous pouvons dire que nous avons amélioré la qualité de notre base de données en stabilisant les variables explicatives ainsi que la variable à expliquer. Maintenant, le jeu de données final est prêt pour la modélisation.

3 Analyse exploratoire

L'objectif de cette section consiste à entreprendre une analyse exploratoire et descriptive afin d'améliorer la compréhension de l'ensemble de données, en vue de formuler une première stratégie de modélisation.

3.1 Analyse de forme

La variable cible du jeu de données est la variable CFL C, représentant la mesure d'adhérence selon le couple pour la régression, et la variable contenant les différents types de contaminants pour la classification. L'ensemble de données final comprend 1052 observations et 33 variables, mais toutes ces variables ne seront pas utilisées. Les variables suivantes seront supprimées : Machine, car il n'y a qu'une seule machine "208 G 117" ; Pneumatique, qui n'a qu'une seule valeur "Pneu rainuré PEX Mt St Dauphin" ; et Décalage/Axe, qui a une seule valeur de 0. De plus, les variables suivantes sont inutiles pour la modélisation : *Nom du Curseur*, *Seuil de départ*, *Position/Axe*, *Décalage/Axe* (avec une seule valeur de 0), *Date*, *Date_txt*, *Heure*, *Heure_txt*, *Pas Min [m]*, *Pas Max [m]*, *ET G%*, *Ic G%*, *ET CFLF*, *ET CFLC*, *Ic CFL C*, *ET Fv*, et *Ic Fv*. Après vérification de la validité des observations, les colonnes suivantes sont retenues : *Vitesse*, *Glissement*, *Moyenne CFL F*, *Moyenne CFL C*, *Moyenne G% [%]*, *Fv (kg)*, *Tsurf (C)*, *T° BDR (C)*, *Contaminant*, et *hauteur (mm)*. Pour la création des modèles, les variables les plus significatives et physiquement interprétables seront choisies parmi celles-ci. En conclusion, une base de données prête pour la modélisation, contenant 1052 observations et 10 variables, est disponible.

3.2 Analyse de fond

3.2.1 La variable cible

Le CFL C dans le jeu de données varie entre 0 et 0.82. 95% des observations ont un CFL inférieur à 0.25, ce qui signifie que les valeurs extrêmes de CFL (5%) sont spécifiques au contaminant 'DRY', ce qui est logique. Le skewness de cette distribution est de 2. Cependant, la médiane est égale à la moyenne, ce qui est contre-intuitif, car on s'attendrait normalement à ce que la moyenne soit nettement supérieure à la médiane dans une distribution fortement asymétrique à droite.

Pour la variable "contaminant", l'effectif de chaque contaminant et son pourcentage sont visualisés dans la figure ci-dessous.

	count	proportion
Contaminant		
NC.C.	232	22.053232
Neige fraiche (B)	191	18.155894
N.C. (B)	140	13.307985
Neige fraiche (G)	129	12.262357
Glace	107	10.171103
N.C. (G)	106	10.076046
SLUSH	70	6.653992
Verglas	58	5.513308
DRY	19	1.806084

FIGURE 14 – l’effectif de chaque contaminant et son pourcentage

Il a été décidé de ne pas intégrer les observations du contaminant "Dry" pour deux raisons :

- Le but de ce travail est de modéliser le CFL C (comme étant une variable à expliquer ou explicative) dans des conditions hivernales. Son étude sur une surface sèche fait l’objet d’autres recherches effectuées par le STAC.
- Ce contaminant constitue moins de 2% des observations de la base de données, avec un effectif de 19 observations. Pour la modélisation en apprentissage automatique, il est difficile de faire confiance à un modèle entraîné avec moins de 19 observations (après division en ensembles de test et d’apprentissage).

3.2.2 Relation variables / variable cible et variables / variables :

Pour analyser la relation entre les variables à expliquer et la variable cible, ou les variables entre elles, la méthode utilisée sera la visualisation des corrélations (voir la figure suivante).




FIGURE 15 – Corrélation entre les variables du jeu de données

Remarques

- **Corrélation entre glissement et moyenne glissement** : Une corrélation extrêmement élevée (0.99987) existe entre "Glissement" et "Moyenne Glissement", on rappelle que "Glissement" correspond au taux de freinage consigne. Ces variables sont quasiment interchangeables en termes d'information qu'elles apportent. Un manque de valeurs de glissement dans l'intervalle de 20 à 100 est constaté. (graphe ci-dessous)
- **Relation linéaire entre CFL C et CFL F** : Il y a une relation linéaire marquée entre "CFL C" et "CFL F", avec une corrélation de 0.93. Cela suggère que ces deux variables soient fortement liées.
- **Faible corrélation entre les variables explicatives** : Les différentes variables explicatives montrent une faible corrélation entre elles, ce qui est bénéfique pour réduire la multicolinéarité et améliorer la performance du modèle.
- **Faible corrélation entre la variable cible et les variables explicatives** : La variable cible présente une faible corrélation avec les variables explicatives, indiquant que les relations entre elles ne sont probablement pas linéaires.




FIGURE 16 – La relation linéaire forte entre le glissement et valeur moyenne de glissement




FIGURE 17 – La relation linéaire forte entre la valeur de CFL C et CFL F

3.3 Commentaires

Glissement et moyenne glissement :

- Les variables "Glissement" et "Moyenne Glissement" fournissent essentiellement la même information. Toutefois, "Moyenne Glissement" est plus précise. Il est difficile de considérer "Glissement" comme une version discrétisée de "Moyenne Glissement" en raison du nombre élevé de modalités (6). Par conséquent, il est essentiel de supprimer l'une des deux variables lors de la modélisation pour améliorer la précision. "Glissement" sera supprimée en faveur de "Moyenne Glissement" pour garder la précision et la flexibilité des modèles.
- Lors des mesures, seuls les glissements consignés 2, 4, 7, 11, 15 et 100 ont été choisis

pour être mesurés. Le manque de mesures sur l'intervalle 20 à 100 se justifie par le fait qu'à une vitesse donnée, la courbe du CFL C en fonction du glissement devrait montrer un plateau ou une courbe faiblement décroissante dans cet intervalle. Dans cet intervalle, les valeurs de CFL sont proches de la valeur maximale de glissement, mais légèrement supérieures.

- Cette remarque (manque des observations) est très importante pour le choix du modèle de régression qui doit respecter certaines contraintes (voir la partie de modélisation).

Décorrélation des Variables Explicatives :

Le fait que les variables explicatives soient décorrélées est un point fort pour la modélisation car :

- Chaque variable apporte une information distincte des autres, ce qui réduit la complexité du modèle.
- Une complexité réduite signifie une variance faible, ce qui conduit à une meilleure précision et à un risque de sur-apprentissage réduit.

Faible Corrélation entre les Variables Explicatives et la Variable Cible :

La faible corrélation entre les variables explicatives et la variable cible est un point faible pour la modélisation linéaire car :

- La relation entre la variable cible et les autres variables n'est pas linéaire.
- Cette remarque suggère l'utilisation d'une régression polynomiale pour mieux capturer les relations non linéaires.

Variable CFL F :

Il n'est pas possible d'utiliser cette variable pour la régression ni pour la classification, car elle compliquerait le modèle en raison de sa grande corrélation avec le CFL C.

Température :

Les températures mesurées en volts (V) sont transformées en degrés Celsius en utilisant les formules suivantes :

$$T_{\text{surf}} (V) = T_{\text{surf}} (V) \times 11.274 - 31.72$$

$$T^{\circ} \text{ BDR} (V) = T^{\circ} \text{ BDR} (V) \times 15.5 - 23.55$$

3.4 La relation entre la nature du contaminant et la différence entre le CFL C et le CFL F

3.4.1 L'influence de la nature du contaminant

Le CFL F mesure la force de freinage s'appliquant sur la roue. Il s'agit de la somme de la force de frottement et de traînée, elle-même engendrée par le cumul du contaminant à l'avant de la roue. C'est pourquoi la valeur du CFL F doit être supérieure à celle du

CFL C. Dans le graphe suivant, l'influence de chaque contaminant sur la différence entre les deux valeurs est représentée :




FIGURE 18 – Différence entre le CFL C et le CFL F par rapport à la nature du contaminant

Seuls les contaminants 'Neige fraîche (G)', 'N.C. (G)', 'NC.C.', 'Glace', 'SLUSH' et 'DRY' sont représentés. Pour le reste des contaminants, les remarques ci-dessous s'appliquent de manière similaire.

La bissectrice est tracée pour vérifier que le CFL C est bien inférieur au CFL F (car la bissectrice représente le cas d'égalité). À l'aide des équations de régression, qui s'écrivent sous la forme $CFL_F = a \cdot CFL_C + b$, l'effet marginal du CFL C est étudié en dérivant par rapport à lui :

$$\frac{d(CFL_F)}{d(CFL_C)} = a$$

Dans tous les cas, $a < 1$, c'est-à-dire que si le CFL C augmente de 1, le CFL F augmente d'une valeur inférieure à 1. On remarque que l'évolution du CFL F est inférieure à celle du CFL C.

À partir de la valeur $\frac{b}{1-a}$, le CFL C sera supérieur au CFL F. Cette remarque est théorique, car pour les contaminants 'Neige fraîche (G)', 'N.C. (G)' et 'NC.C.', la valeur $\frac{b}{1-a}$ est supérieure à 1, alors que le CFL C ne va pas excéder 1.

Pour 'Glace' et 'SLUSH', $\frac{b}{1-a}$ vaut respectivement 0.43 et 0.71, mais dans les conditions hivernales, le CFL C ne dépasse généralement pas 0.3.

Pour 'DRY', l'égalité des coefficients n'est pas présente car l'étalonnage du CFL C

par rapport au CFL F s'est fait sur piste humide, ceci explique donc un biais lorsque la chaussée était sèche en plus d'être rainurée

3.4.2 Etude de la relation inverse

Dans cette partie, la question suivante sera abordée : peut-on déterminer les contaminants, c'est-à-dire savoir de quel contaminant il s'agit, uniquement en se basant sur l'écart entre CFL F et CFL C ? Pour ce faire, la distribution des écarts entre CFL C et CFL F pour chaque contaminant sera présentée à l'aide de violin plots. Les violin plots sont utilisés ici car ils offrent une représentation plus détaillée des distributions de données comparativement aux box plots. Contrairement aux box plots, qui ne montrent que des résumés statistiques de base (quartiles et médianes), les violin plots révèlent la densité de probabilité des données à différentes valeurs, permettant ainsi une meilleure visualisation de la distribution globale et des éventuelles multimodalités.




FIGURE 19 – Distribution des écarts entre CFL C et CFL F pour chaque contaminant

D'après ce graphe, il n'est pas évident de déterminer la nature des contaminants uniquement à l'aide de la différence entre le CFL C et le CFL F. C'est pourquoi un test statistique, le test ANOVA (Analyse de la Variance), a été choisi pour évaluer si cette différence est discriminante.

Le test ANOVA est une méthode statistique utilisée pour vérifier s'il existe des différences significatives entre les moyennes de plusieurs groupes, mais il ne fournit pas de détails sur les groupes spécifiques qui peuvent être distingués ni sur ceux qui ont des moyennes similaires, ce qui le rend moins puissant pour des analyses fines. Ce test a été utilisé dans cette section uniquement à des fins descriptives et non pour un objectif de modélisation.

En pratique, pour déterminer précisément le passage d'un contaminant à un autre, une approche alternative telle que la régression logistique pourrait être utilisée, car elle permet d'identifier les points de transition entre les groupes. Cependant, cette méthode n'a pas été employée ici car il ne s'agit pas de modélisation, mais simplement d'une description.

Pour le test ANOVA, l'hypothèse nulle (H_0) stipule que les moyennes des écarts entre CFL C et CFL F sont égales pour tous les contaminants, c'est-à-dire qu'il n'y a pas de différence significative entre eux. L'hypothèse alternative (H_1) stipule que les moyennes des écarts ne sont pas toutes égales, indiquant la présence d'au moins une différence significative entre les groupes de contaminants.

Le test ANOVA produit une valeur p (p-value), qui est la probabilité d'observer un résultat aussi extrême que celui obtenu, en supposant que l'hypothèse nulle soit vraie. Si la p-value est inférieure à un seuil prédéterminé (généralement 0.05), l'hypothèse nulle est rejetée, indiquant qu'il existe des différences significatives entre les groupes.

Le résultat du test ANOVA est le suivant : $p\text{-value} = 3.592 \times 10^{-143}$. Étant donné que cette p-value est extrêmement inférieure au seuil de 0.05, l'hypothèse nulle (H_0) est rejetée.

Le rejet de l'hypothèse nulle indique qu'il existe des différences significatives entre les moyennes des écarts entre CFL C et CFL F pour les différents groupes de contaminants. En d'autres termes, les écarts entre CFL C et CFL F varient de manière significative en fonction du type de contaminant. Cela signifie qu'il est possible de discriminer les différents contaminants en utilisant cette différence.

Toutefois, comme mentionné précédemment, l'ANOVA n'indique pas quels groupes spécifiques sont différenciés. Pour une analyse plus détaillée, une régression logistique pourrait être plus appropriée, mais n'a pas été utilisée ici.

D'après le graphe précédent, et compte tenu de la nature similaire de certains contaminants, il est possible de confondre 'Neige fraîche (B)' et 'Neige fraîche (G)', ainsi que 'N.C. (B)' et 'N.C. (G)'. Cette observation sera particulièrement intéressante dans la partie dédiée à la classification des contaminants.

4 Présentation des méthodes utilisées

Dans cette section, un examen détaillé des méthodes et techniques employées dans ce projet sera effectué, en mettant l'accent sur leur fondement théorique.

4.1 Régression linéaire

La régression linéaire est une méthode utilisée pour modéliser la relation entre une variable dépendante y et une ou plusieurs variables explicatives $\mathbf{X}$. Le modèle de régression linéaire est défini par :

$$y_i = \beta_0 + \sum_{j=1}^p \beta_j x_{ij} + \epsilon_i$$

où y_i est la valeur prédite, β_0 est l'intercept, β_j sont les coefficients des variables explicatives x_{ij} , et ϵ_i est l'erreur résiduelle.

L'objectif est de minimiser la somme des carrés des erreurs (fonction de coût) :

$$J(\beta) = \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

Les coefficients β_j sont trouvés en minimisant $J(\beta)$ à l'aide de méthodes d'optimisation comme la descente de gradient ou LBFGS.

Les avantages de la régression linéaire incluent :

- Simplicité et facilité d'interprétation.
- Efficacité pour les relations linéaires entre les variables.
- Rapidité de calcul pour des modèles simples.

Pour plus de détails, vous pouvez consulter cette ressource sur la régression linéaire.

4.2 Régression Logistique Multinomiale

La régression logistique est une méthode de classification utilisée pour prédire la probabilité d'appartenance à une classe en fonction des variables explicatives. La probabilité qu'une observation $\mathbf{x}_i$ appartienne à la classe k est donnée par :

$$P(y_i = k \mid \mathbf{x}_i) = \frac{\exp(\beta_{k0} + \sum_{j=1}^p \beta_{kj} x_{ij})}{\sum_{l=0}^{K-1} \exp(\beta_{l0} + \sum_{j=1}^p \beta_{lj} x_{ij})}$$

Cette formule utilise la fonction softmax pour convertir les scores en probabilités. La fonction softmax assure que les probabilités pour toutes les classes K sommées ensemble sont égales à 1.

La fonction de coût (log-loss) à minimiser est :

$$J(\beta) = -\log L(\beta)$$

La log-vraisemblance pour l'ensemble des données est :

$$\log L(\beta) = \sum_{i=1}^N \log \left(\frac{\exp(\beta_{y_i0} + \sum_{j=1}^p \beta_{y_ij} x_{ij})}{\sum_{l=0}^{K-1} \exp(\beta_{l0} + \sum_{j=1}^p \beta_{lj} x_{ij})} \right)$$

Les coefficients β_{kj} et les intercepts β_{k0} sont optimisés en minimisant la fonction de coût à l'aide de méthodes comme la descente de gradient ou LBFGS.

Les avantages de la régression logistique multinomiale incluent :

- Simplicité d'interprétation des coefficients.
- Probabilités prédictives bien calibrées grâce à l'utilisation de la fonction softmax.

Pour plus de détails, vous pouvez consulter cette ressource sur la régression logistique multinomiale.

4.3 Random Forest

Un Random Forest (ou forêt aléatoire) est un algorithme d'apprentissage automatique supervisé proposé par Leo Breiman en 2001. Il s'agit d'une illustration de ce que l'on appelle une méthode d'ensemble, terme désignant toutes les méthodes d'apprentissage statistique qui utilisent plusieurs estimations pour construire un nouveau modèle, agrégeant ainsi toutes les prédictions.

Random Forest est une méthode d'apprentissage supervisé qui peut être utilisée pour des tâches de classification et de régression. Elle fonctionne en construisant une multitude d'arbres de décision lors de l'entraînement et en sortant la moyenne des prédictions (régression) ou le vote majoritaire (classification) des arbres individuels.

Les avantages de Random Forest incluent :

- Robustesse contre le sur-apprentissage.
- Capacité à gérer de grands ensembles de données avec de nombreuses caractéristiques.
- Capacité à gérer les valeurs manquantes et à maintenir une bonne performance avec des données bruyantes.




FIGURE 20 – Exemple illustratif d'un arbre de décision pour la régression (averaging) ou la classification (voting) (source : [3])

4.3.1 Random Forest Regressor

Random Forest Regressor utilise un ensemble d'arbres de décision pour effectuer des tâches de régression, en combinant leurs prédictions pour obtenir une estimation plus précise.

Critères de division dans chaque arbre

Lors de la construction de chaque arbre de décision dans la forêt, l'objectif est de diviser les données de manière à minimiser l'erreur dans les sous-ensembles résultants. Les critères de division incluent :

- **Réduction de la variance (VR) :**

$$VR = \text{Variance}_{\text{parent}} - \left(\frac{N_{\text{gauche}}}{N_{\text{total}}} \cdot \text{Variance}_{\text{gauche}} + \frac{N_{\text{droite}}}{N_{\text{total}}} \cdot \text{Variance}_{\text{droite}} \right)$$

- **Erreur quadratique moyenne (Mean Squared Error, MSE) :**

$$MSE = \frac{1}{N_{\text{total}}} (N_{\text{gauche}} \cdot \text{MSE}_{\text{gauche}} + N_{\text{droite}} \cdot \text{MSE}_{\text{droite}})$$

Processus de division dans chaque arbre

- **Sélection de la meilleure division :**
 - Examiner toutes les valeurs possibles comme points de division pour chaque caractéristique.
 - Calculer la réduction de la variance ou le MSE pour chaque point de division.
 - Sélectionner la division qui minimise l'erreur.
- **Application de la division :**
 - Diviser le nœud en deux sous-ensembles basés sur la valeur de la caractéristique choisie.
 - Répéter récursivement le processus pour chaque sous-ensemble jusqu'à atteindre les critères d'arrêt.

Autres hyperparamètres du Random Forest Regressor

- **Nombre d'arbres (n_estimators) :** Le nombre d'arbres de décision dans la forêt. Un nombre plus élevé d'arbres peut améliorer la précision mais augmente le temps de calcul.
- **Profondeur maximale de l'arbre (max_depth) :** Limite la profondeur de chaque arbre pour prévenir le surapprentissage.
- **Nombre minimum d'échantillons par nœud (min_samples_split) :** Nombre minimum d'échantillons requis pour diviser un nœud.
- **Nombre minimum d'échantillons dans une feuille (min_samples_leaf) :** Nombre minimum d'échantillons requis pour être dans une feuille.

- **Caractéristiques à considérer pour chaque division** (`max_features`) : Nombre de caractéristiques à considérer pour trouver la meilleure division à chaque nœud.

4.3.2 Random Forest Classifier

Random Forest Classifier utilise un ensemble d'arbres de décision pour effectuer des tâches de classification, en combinant leurs prédictions pour obtenir une estimation plus précise.

Critères de division dans chaque arbre

Lors de la construction de chaque arbre de décision dans la forêt, l'objectif est de diviser les données de manière à maximiser l'homogénéité des sous-ensembles résultants. Les critères de division incluent :

- **Entropie** :

$$\text{Entropie} = - \sum_{k=1}^K p_k \log(p_k)$$

où p_k est la proportion des instances appartenant à la classe k .

- **Indice de Gini** :

$$\text{Gini} = 1 - \sum_{k=1}^K p_k^2$$

où p_k est la proportion des instances appartenant à la classe k .

Processus de division dans chaque arbre

Les arbres de décision utilisent un processus structuré pour diviser les données en sous-ensembles de plus en plus homogènes.

- **Sélection de la meilleure division** : Examiner toutes les valeurs possibles comme points de division pour chaque caractéristique, puis calculer l'entropie ou l'indice de Gini pour chaque point de division et sélectionner la division qui minimise l'impureté (entropie ou Gini).
- **Application de la division** : Diviser le nœud en deux sous-ensembles basés sur la valeur de la caractéristique choisie et répéter récursivement le processus pour chaque sous-ensemble jusqu'à atteindre les critères d'arrêt.

Comme pour la régression, le Random Forest Classifier possède les mêmes hyperparamètres que ceux cités dans la section précédente.

Pour plus de détails, vous pouvez consulter cette ressource sur Random Forest.

4.4 XGBoost

XGBoost (Extreme Gradient Boosting) est une bibliothèque d'apprentissage automatique optimisée pour la performance et la vitesse. Elle implémente des algorithmes de boosting de gradient qui permettent de construire de puissants modèles prédictifs en combinant les prédictions de plusieurs modèles faibles, généralement des arbres de décision.

Les avantages de XGBoost incluent :

- Haute performance grâce à l'optimisation des calculs.
- Support natif pour le traitement des valeurs manquantes. Cela signifie que XGBoost peut gérer directement les valeurs manquantes dans les données sans nécessiter de prétraitement ou d'imputation. Par exemple, lors de la construction d'un arbre de décision, si une caractéristique contient des valeurs manquantes, XGBoost détermine automatiquement la meilleure façon de traiter ces valeurs en fonction des informations disponibles, en décidant si les données manquantes doivent aller à gauche ou à droite du point de division.
- Capacité à gérer les données tabulaires et les grandes bases de données.

4.4.1 XGBoost Regressor

XGBoost Regressor est utilisé pour les tâches de régression, où l'objectif est de prédire une valeur continue. Il optimise une fonction de coût spécifique, telle que la somme des carrés des erreurs (MSE), en ajustant les arbres de décision successifs pour minimiser les erreurs résiduelles des prédictions précédentes.

La fonction de coût à minimiser dans XGBoost Regressor est :

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

Les hyperparamètres importants incluent le nombre d'arbres (`n_estimators`), le taux d'apprentissage (`learning_rate`), et la profondeur maximale des arbres (`max_depth`).

4.4.2 XGBoost Classifier

XGBoost Classifier est utilisé pour les tâches de classification, où l'objectif est de prédire la classe d'une observation. Il optimise une fonction de coût comme l'entropie ou l'indice de Gini pour améliorer les performances de classification.

La fonction de coût couramment utilisée est l'entropie :

$$Entropy = - \sum_{k=1}^K p_k \log(p_k)$$

Les hyperparamètres importants incluent le nombre d'arbres (`n_estimators`), le taux d'apprentissage (`learning_rate`), et la profondeur maximale des arbres (`max_depth`).

Pour plus de détails, vous pouvez consulter cette ressource sur XGBoost.

4.5 Métriques de régression

Pour évaluer les performances des modèles de régression, plusieurs métriques sont utilisées :

- **Mean Squared Error (MSE)** : Le MSE mesure la moyenne des carrés des erreurs, c'est-à-dire les différences entre les valeurs prédites et les valeurs réelles :

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

Le MSE est utile pour évaluer la précision globale du modèle, mais il est sensible aux valeurs aberrantes.

- **Root Mean Squared Error (RMSE)** : Le RMSE est la racine carrée du MSE et fournit une mesure de l'erreur en unités des valeurs observées :

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2}$$

Le RMSE est souvent préféré au MAE car il pénalise plus fortement les grandes erreurs, ce qui peut être pertinent dans des contextes où de grandes erreurs sont particulièrement indésirables.

- **Mean Absolute Error (MAE)** : Le MAE mesure la moyenne des erreurs absolues entre les valeurs prédites et les valeurs réelles :

$$MAE = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i|$$

Le MAE est moins sensible aux outliers.

- **Coefficient de détermination (R^2)** : Le R^2 mesure la proportion de la variance des valeurs dépendantes expliquée par le modèle. Il compare les prédictions du modèle réalisé avec celles du pire modèle raisonnable, qui est la moyenne :

$$R^2 = 1 - \frac{\sum_{i=1}^N (y_i - \hat{y}_i)^2}{\sum_{i=1}^N (y_i - \bar{y})^2}$$

Le R^2 varie entre 0 et 1, où 1 indique un modèle parfait.

Les avantages de ces métriques incluent :

- **MSE et RMSE** : Sensibles aux grandes erreurs et pénalisent sévèrement les données aberrantes.
- **RMSE** : Préféré au MAE dans des contextes où de grandes erreurs sont particulièrement indésirables.
- **MAE** : Moins sensible aux données aberrantes., fournit une mesure robuste de l'erreur moyenne.
- **R^2** : Intuitif et utile pour comprendre la proportion de la variance expliquée par le modèle.

Pour plus de détails, vous pouvez consulter cette ressource sur les métriques de régression.

4.6 Matrice de confusion

La matrice de confusion est définie pour un classifieur fixé et permet d'analyser plus finement ses performances sur un échantillon de test. Nous allons la détailler dans le cas général de K classes. La matrice de confusion compare les prédictions aux vraies valeurs observées pour toutes les classes K .

À l'aide de la matrice de confusion, on définit plusieurs grandeurs d'intérêt qui permettent de construire des indicateurs de qualité de classification :

Valeurs observées	Valeurs prédites			
	Classe 1	Classe 2	...	Classe K
Classe 1	C_{11}	C_{12}	...	C_{1K}
Classe 2	C_{21}	C_{22}	...	C_{2K}
...	...	...	...	...
Classe K	C_{K1}	C_{K2}	...	C_{KK}

TABLE 1 – Exemple de matrice de confusion pour K classes.

- **Accuracy (Taux de bien classés)** : C'est l'estimateur de $P(\hat{Y} = Y)$, obtenu par la formule :

$$\text{Accuracy} = \frac{\sum_{i=1}^K C_{ii}}{\sum_{i=1}^K \sum_{j=1}^K C_{ij}}$$

L'accuracy mesure la proportion de prédictions correctes parmi l'ensemble des prédictions.

- **Recall (Rappel)** : Pour chaque classe i , c'est l'estimateur de $P(\hat{Y} = i | Y = i)$, obtenu par la formule :

$$\text{Recall}_i = \frac{C_{ii}}{\sum_{j=1}^K C_{ij}}$$

Le rappel mesure la capacité du classifieur à identifier correctement les instances positives de chaque classe.

- **Precision (Précision)** : Pour chaque classe i , c'est l'estimateur de $P(Y = i | \hat{Y} = i)$, obtenu par la formule :

$$\text{Precision}_i = \frac{C_{ii}}{\sum_{j=1}^K C_{ji}}$$

La précision mesure la proportion de véritables instances positives parmi celles prédites positives pour chaque classe.

- **F1 Score** : Pour chaque classe i , c'est la moyenne harmonique de la précision et du rappel, obtenu par la formule :

$$\text{F1 Score}_i = \frac{2 \times \text{Precision}_i \times \text{Recall}_i}{\text{Precision}_i + \text{Recall}_i}$$

Le F1 score est utile pour évaluer la performance globale du classifieur lorsqu'il y a un équilibre entre précision et rappel.

Les avantages de ces métriques incluent :

- **Accuracy** : Simple à comprendre et intuitive, elle donne une vue d'ensemble de la performance du modèle.
- **Recall** : Important dans les cas où les faux négatifs sont plus coûteux que les faux positifs.
- **Precision** : Cruciale lorsque les faux positifs sont coûteux, par exemple dans le filtrage de spam.
- **F1 Score** : Utile lorsque l'on recherche un équilibre entre la précision et le rappel, surtout dans des ensembles de données déséquilibrés.

Pour plus de détails, vous pouvez consulter cette ressource sur la matrice de confusion et les métriques de performance.

5 Modélisation du CFL C

L'objectif de cette section est de réaliser une modélisation du CFL, en commençant par une approche linéaire puis ensembliste, en fonction des variables explicatives. Une méthode d'apprentissage statistique sera adoptée, divisant l'échantillon en deux sous-échantillons : un échantillon d'apprentissage et un échantillon de test. De plus, lors de la recherche des hyperparamètres, des échantillons de validation seront utilisés via une validation croisée. Il est impératif que ces deux sous-échantillons soient représentatifs, ce qui sera vérifié ultérieurement.

Le but est de créer des modèles pour chaque contaminant, autrement dit, entraîner huit modèles de prédiction à l'aide des variables explicatives. Parmi ces variables, il a été observé que celle décrivant la masse, centrée sur 180 kg, présente une faible variabilité pour chaque contaminant. Une observation similaire s'applique à la température de surface et à la température de bande de roulement. comme illustré dans la figure 21.

	Fv (kg)	Tsurf (C)	T° BDR (C)
Contaminant			
Glace	0.928291	0.874199	1.670012
N.C. (B)	1.091654	0.622514	0.292835
N.C. (G)	1.415796	0.717204	0.300757
NC.C.	1.282551	1.474958	1.289923
Neige fraîche (B)	1.001469	0.497656	0.377927
Neige fraîche (G)	1.161160	0.464036	0.440808
SLUSH	2.009606	0.060289	0.079858
Verglas	1.726502	0.757842	1.514190

FIGURE 21 – Écart type des trois variables pour chaque contaminant

En raison de cette faible variabilité, il a été décidé d'éliminer ces variables afin de prévenir des problèmes de colinéarité et de corrélation, améliorant ainsi la précision des modèles.

Les variables restantes, la vitesse et le glissement, serviront donc à expliquer la variable cible.

5.1 Modélisation linéaire par morceau pénalisée

Dans cette section, intitulée *Modélisation linéaire par morceau pénalisée*, l'approche de la régression linéaire classique ne sera pas suivie. En effet, en raison de l'absence de données dans l'intervalle de 20 à 100 (aucune observation disponible dans cet intervalle pour tous les contaminants), les modèles de régression fonctionnent bien là où des données sont présentes, mais ils produisent des résultats erronés dans l'intervalle de 20 à 100




FIGURE 22 – Résultats erronés de la régression linéaire dans l’intervalle de 20 à 100 pour le contaminant N.C. (B) pour la vitesse 65Km/h

Dans cette figure, le modèle a montré de meilleures performances, avec un R^2 de 0.91 et un RMSE de 0.016. Cependant, il n’a pas respecté la contrainte physique et semble avoir surappris les données.

Physiquement, nous devrions observer un plateau ou une courbe non linéaire faiblement décroissante dans cet intervalle. Cette réalité physique n’est pas capturée par une simple régression linéaire. Le défi dans une telle modélisation est de refléter la réalité physique tout en maintenant une bonne performance statistique et une interprétabilité. Lors des mesures, les physiciens n’ont pas mesuré les valeurs dans cet intervalle car ils s’attendaient à y observer un plateau. Il n’était donc pas nécessaire d’augmenter les coûts de mesure. Cependant, un modèle statistique ne comprend pas ce qu’est un plateau et, sans connaître sa forme exacte, il n’est pas possible de le modéliser correctement.

Nous connaissons néanmoins ces contraintes : Le glissement où le modèle atteint son maximum doit correspondre au glissement où les observations atteignent leur maximum. Par exemple, pour le contaminant neige fraîche (B), la valeur maximale du CFL est atteinte pour un glissement de 10.73% ; ainsi, le modèle que nous construisons doit également atteindre son maximum en ce point.

De plus, il est essentiel (sauf pour le slush) que le modèle génère une fonction qui stagne sous forme d’une asymptote horizontale après avoir atteint son maximum et n’atteigne le minimum qu’en arrivant au glissement maximal (c’est-à-dire, sans décroissance suivie d’une croissance ou l’inverse).

Enfin, la dernière contrainte est que la fonction doit commencer, pour un glissement nul, à une petite valeur strictement supérieure à 0.

Des tentatives ont été faites pour travailler avec un modèle de régression en ajoutant des contraintes et en modifiant la forme de la fonction objectif. Le problème était que l'imposition d'un maximum déplacé vers le maximum réel déstabilisait la fonction de régression après ce point, générant toujours un problème d'inversion entre le maximum et le glissement maximal. Même en ajoutant des contraintes visant à minimiser la dérivée seconde de la fonction de régression pour obtenir une forme tendant vers la concavité, il a été constaté que le modèle entre 0 et le maximum ne devait pas être le même qu'entre ce point et la valeur de 100% du glissement.

Cela justifie le choix de modélisation par morceau pour mieux représenter le comportement des contaminants en fonction des variables explicatives.

La contrainte avec la régression par morceau est que le choix du point de coupure doit maximiser la performance globale du modèle et être situé après le glissement où la fonction atteint son maximum. De plus, il est essentiel d'avoir une fonction continue, notamment au point de coupure. Ce point ne doit pas apparaître comme une séparation évidente entre deux fonctions distinctes. En d'autres termes, une dérivée à droite qui égale à la dérivée à gauche en ce point est nécessaire. Ainsi, la fonction résultante doit être de classe C^1 (une fonction dérivable dont la dérivée est continue).

La première étape dans cette modélisation est de choisir le point de coupure. Sachant que le modèle change de comportement en fonction de la vitesse, le point de coupure doit être déterminé pour chaque vitesse.

5.1.1 Création du Modèle

En fixant la vitesse, la seule variable explicative restante est le glissement. L'objectif est d'homogénéiser les équations entre tous les contaminants, c'est-à-dire que le CFL doit être expliqué par les mêmes variables explicatives et les mêmes contraintes. La différence d'un modèle à un autre réside dans le changement des poids des contraintes et les coefficients de l'équation du modèle global (ce qui modifie évidemment le point de coupure d'un contaminant à un autre).

Après application de l'ingénierie des données (appliquant des modifications à l'entrée, qui est le glissement dans ce cas, pour extraire d'autres variables explicatives dépendant de cette entrée afin de détecter les relations entre la variable brute d'entrée et la variable cible, et également pour extraire les relations non linéaires entre ces deux variables), et après plusieurs essais statistiques et en tenant compte des recommandations du physicien, il a été décidé d'adopter cette forme de fonction pour tous les modèles :

$$f(x) = \begin{cases} a_1 + b_1 \cdot x + c_1 \cdot x^2 & \text{si } x < x_k \\ a_2 + b_2 \cdot \log(x) & \text{si } x > x_k \end{cases}$$

où x_k est le point de coupure et x est le glissement.

Le point de coupure est choisi pour chaque contaminant de telle sorte qu'il maximise la performance globale du modèle (représentée par les valeurs de R^2 et le RMSE).

L'étape la plus technique de cette modélisation est désormais de traduire les contraintes et l'objectif en langage mathématique pour déterminer les valeurs des coefficients. L'objectif est de formuler un problème de programmation non linéaire, visant à maximiser le gain (la performance globale du modèle) et à minimiser les pertes (la fonction coût, représentée par la fonction objectif). Le tout doit respecter les contraintes opérationnelles imposées par la réalité physique du modèle.

Le problème non linéaire que nous cherchons à optimiser, avec les contraintes strictes et la fonction objectif, est formulé comme suit :

$$\begin{aligned} \min \quad & z = \sum (y_i - f(x_i))^2 \\ \text{s.c.} \quad & \begin{cases} a_1 + b_1 \cdot x_k + c_1 \cdot x_k^2 = a_2 + b_2 \cdot \log(x_k) \\ a_1 > 0 \\ \arg \max(f(x) \cdot \mathbf{1}_{\{x < x_k\}}) = \arg \max(y) \\ \arg \min(f(x) \cdot \mathbf{1}_{\{x \geq x_k\}}) = g_{100} \\ \frac{d(f(x) \cdot \mathbf{1}_{\{x \geq x_k\}})}{dx} < 0 \\ \left. \frac{df(x)}{dx} \right|_{x=x_k^-} = \left. \frac{df(x)}{dx} \right|_{x=x_k^+} \end{cases} \end{aligned}$$

où x_k est le point de coupure, g_{100} est le glissement consigne de valeur 100%, et $\mathbf{1}_{\{x \geq x_k\}}$ est la fonction indicatrice égale à 1 si $x \geq x_k$ et 0 sinon.

Explication des contraintes du modèle :

- La fonction objectif sert à minimiser l'écart entre les valeurs réelles et les valeurs prédites (c'est la fonction MSE).
- La première contrainte assure la continuité de f à droite et à gauche du point de coupure.
- La deuxième contrainte assure un début du modèle par une valeur strictement supérieure à 0.
- La troisième contrainte garantit que l'arg max du modèle avant le point de coupure est égal au glissement de l'observation où le CFL C est maximal.
- La quatrième contrainte montre que l'argmin du modèle après le point de coupure doit correspondre au glissement consigne de 100.
- La cinquième contrainte montre que la fonction doit être strictement décroissante après le point de coupure.
- La sixième contrainte garantit que le modèle est dérivable au point de coupure.

Lors de la résolution du système non linéaire précédent, il a été constaté que l'introduction de la troisième contrainte conduisait à un espace de solution vide, c'est-à-dire un problème sans solution. Pour surmonter cette difficulté, l'écart entre les deux argmax a été minimisé sans imposer une égalité stricte. Un nouveau terme a été introduit dans la

fonction objectif avec un certain poids, suivant la logique de la régression par pénalisation.

L'argmax, qui est le point où la fonction atteint son maximum, dépend des coefficients du modèle. Son introduction dans la fonction objectif permet d'ajuster ces coefficients afin de minimiser l'écart entre les deux argmax. Il est à noter que pour calculer l'argmax, une fonction en Python est utilisée, laquelle le trouve directement sans passer par des équations explicites.

En ce qui concerne la quatrième contrainte, elle manque de précision, car le g_{100} , correspondant à un glissement consigne de 100%, englobe plusieurs valeurs de glissement moyen variant entre 97 et 100. Le choix d'une valeur parmi ces valeurs serait arbitraire et n'aurait aucun sens physique ni mathématique. Pour résoudre ce problème, cette contrainte a été supprimée et une pénalisation a été imposée sur le modèle à droite du point de coupure pour forcer une pente faiblement décroissante (à l'aide de la cinquième contrainte) qui passe par la distribution des points de g_{100} .

Pour la deuxième contrainte, qui impose que la constante de la première partie du modèle soit strictement positive, un terme de pénalisation sera ajouté sur ce coefficient afin de garantir une valeur strictement positive, mais faible pour ce coefficient. Enfin, afin de rendre le modèle plus stable, une pénalisation sera également appliquée aux coefficients autres que la constante de la première partie du modèle.

Finalement, le problème d'optimisation peut être reformulé comme suit :

$$\begin{aligned}
\min \quad z = & \sum (y_i - f(x_i))^2 \\
& + \lambda_1 |\arg \max(f(x) \cdot \mathbf{1}_{\{x < x_k\}}) - \arg \max(y)| \\
& + \lambda_2 |a_1| \\
& + \lambda_3 (|b_1| + |c_1|) \\
& + \lambda_4 (|a_2| + |b_2|) \\
\text{s.c.} \quad & \begin{cases} a_1 + b_1 \cdot x_k + c_1 \cdot x_k^2 = a_2 + b_2 \cdot \log(x_k) \\ a_1 > 0 \\ b_2 < 0 \\ b_1 + 2 \cdot c_1 \cdot x_k = \frac{b_2}{x_k} \end{cases}
\end{aligned}$$

où λ_1 , λ_2 , λ_3 , et λ_4 sont des coefficients de pénalisation (des poids) ajustés pour équilibrer les différentes contraintes.

Explication des pénalisations et des contraintes :

- La fonction objectif vise à minimiser l'écart entre les valeurs réelles et les valeurs prédites (c'est la fonction MSE).

- La première pénalisation (λ_1) minimise l'écart entre l'argmax de la fonction de régression (avant le point de coupure) et l'argmax des observations.

- La deuxième pénalisation (λ_2) assure que a_1 est minimal, ce qui contribue à ce que la fonction commence par une valeur strictement supérieure à 0.

- La troisième pénalisation (λ_3) minimise les valeurs absolues de b_1 et c_1 pour garantir la stabilité du modèle avant le point de coupure.

- La quatrième pénalisation (λ_4) minimise les valeurs absolues de a_2 et b_2 pour garantir la stabilité du modèle après le point de coupure.

- La première contrainte assure la continuité de f à droite et à gauche du point de coupure.

- La deuxième contrainte assure un début du modèle par une valeur strictement supérieure à 0.

- Pour les deux dernières contraintes, sachant que :

$$f'(x) = \begin{cases} b_1 + 2 \cdot c_1 \cdot x & \text{si } x < x_k \\ \frac{b_2}{x} & \text{si } x > x_k \end{cases}$$

Donc :

$$\frac{d(f(x) \cdot \mathbf{1}_{\{x \geq x_k\}})}{dx} < 0$$

est équivalent à dire que $b_2 < 0$, et

$$\left. \frac{df(x)}{dx} \right|_{x=x_k^-} = \left. \frac{df(x)}{dx} \right|_{x=x_k^+}$$

est équivalent à dire que

$$b_1 + 2 \cdot c_1 \cdot x_k = \frac{b_2}{x_k}$$

5.1.2 Résultat des modèles

Pour assurer la représentativité des deux échantillons, test et apprentissage, la variable du glissement a été discrétisée et stratifiée par rapport à cette discrétisation. Par exemple, pour le premier contaminant, Neige fraîche (B), cinq groupes ont été créés : un groupe pour les glissements inférieurs à 6, un autre entre 6 et 11, un autre entre 11 et 14, un autre entre 14 et 16, et un dernier pour les glissements supérieurs à 16. Ensuite, une division des échantillons par stratification par rapport à cette discrétisation a été effectuée.

Cette discrétisation varie d'un contaminant à un autre. Les seuils ne sont pas choisis aléatoirement, mais sont déterminés pour assurer une discrétisation fine tout en gardant un nombre minimum de représentants pour chaque intervalle.

Dans cette partie, quatre modèles seront présentés : ceux des contaminants neige fraîche (B), NC.C., Glace et Slush. Pour le reste des modèles, ils seront fournis dans la deuxième partie de l'annexe (Partie B).

Neige fraîche (B) :

Pour le contaminant Neige fraîche (B), les poids choisis sont les suivants :
 $\lambda_1 = 0.002$, $\lambda_2 = 0.003$, $\lambda_3 = 0$, $\lambda_4 = 0.0007$,
avec un point de coupure choisi à 11.29.

Cela a généré le modèle suivant :

$$f(x) \cdot 10^{-5} = \begin{cases} 3883.45 + 2118.96 \cdot x - 96.88 \cdot x^2 & \text{si } x \leq 11.29\% \\ 17310.69 - 764.36 \cdot \log(x) & \text{si } x > 11.29\% \end{cases}$$

Le modèle a donné une bonne performance sur l'échantillon de test avec un $R^2 = 0.76$.
Notre modèle respecte toutes les contraintes physiques (voir la figure suivante).




FIGURE 23 – Régression par morceau pour le contaminant Neige fraîche (B)

NC.C. :

Pour le contaminant NC.C., les poids choisis sont les suivants :
 $\lambda_1 = 0.0005$, $\lambda_2 = 0.0025$, $\lambda_3 = 0$, $\lambda_4 = 0.0003$,

avec un point de coupure choisi à 11.11.

Cela a généré le modèle suivant :

$$f(x) \cdot 10^{-5} = \begin{cases} 3508.58 + 3899.52 \cdot x - 185.1 \cdot x^2 & \text{si } x \leq 11.11\% \\ 29645.2 - 2350.82 \cdot \log(x) & \text{si } x > 11.11\% \end{cases}$$

Le modèle a donné une bonne performance sur l'échantillon de test avec un $R^2 = 0.83$.
On peut voir que notre modèle respecte toutes les contraintes physiques.




FIGURE 24 – Régression par morceau pour le contaminant NC.C.

Glace :

$$f(x) \cdot 10^{-5} = \begin{cases} 0 + 1241.13 \cdot x - 39.81 \cdot x^2 & \text{si } x \leq 17\% \\ 15014.33 - 1913.57 \cdot \log(x) & \text{si } x > 17\% \end{cases}$$




FIGURE 25 – Régression par morceau pour le contaminant Glace
avec $\lambda_1 = 0.001$, $\lambda_2 = 10$, $\lambda_3 = 0.0055$, $\lambda_4 = 0.0001$,

Dans le modèle précédent, la constante de la première partie n'est pas réellement nulle, mais elle est très faible tout en restant supérieure à 0.

Slush :

En définissant les contraintes, pour la troisième contrainte et celle qui déclare que le minimum après le point de coupure doit être au glissement consigne 100%, nous avons fait une exception pour le slush. C'est-à-dire que pour le slush, le maximum de la courbe doit être au glissement consigne 100% et le modèle après le point de coupure doit être croissant (l'augmentation du CFL C provient de la trainée générée par le cumul de slush à l'avant de la roue qui n'a pas pu être totalement supprimé).

En modifiant les contraintes, nous avons obtenu :

$$f(x) \cdot 10^{-5} = \begin{cases} 549.17 + 1231.92 \cdot x - 38.79 \cdot x^2 & \text{si } x \leq 15\% \\ 7527.6 + 1023.96 \cdot \log(x) & \text{si } x > 15\% \end{cases}$$




FIGURE 26 – Régression par morceau pour le contaminant slush avec $\lambda_1 = 0$, $\lambda_2 = 0.005$, $\lambda_3 = 0$, $\lambda_4 = 0$

Remarque :

Pour les formules des modèles précédents, les valeurs réelles des coefficients sont données avec 18 chiffres après la virgule. Cependant, pour des raisons de clarté, nous avons utilisé une précision de 10^{-5} .

Nous pouvons maintenant visualiser les modèles précédents dans un même graphique. On peut également constater que ces figures ont à peu près les mêmes allures que celles de la figure 2 (surtout pour la neige et la glace).




FIGURE 27 – CFL de certains contaminants hivernaux à 65 km/h

Influence de la vitesse sur le CFL :

Les modèles présentés dans cette section ont été créés pour une vitesse de 65 km/h. À une vitesse inférieure à 65 km/h, en prenant comme référence celle de notre jeu de données, soit 40 km/h, le CFL à cette vitesse est à peu près le même que celui à 65 km/h pour un faible taux de freinage. Il devient supérieur autour du glissement où le CFL atteint son maximum, et inférieur autour d'une roue bloquée (glissement tendant vers 100%). (voir les figures ci-dessous).

La diminution d'adhérence maximale en fonction de la vitesse est présente pour tous les contaminants. Cependant on note une inversion de l'adhérence selon la vitesse pour une roue bloquée. Ceci s'explique par le fait qu'on ne puisse pas s'affranchir totalement de l'effet de traînée générée à haute vitesse sur des contaminants tel que la neige fraîche, la neige compactée ou le SLUSH. Cela entraîne donc une ré-hausse du CFL C.




FIGURE 28 – Influence de la vitesse sur le CFL pour le contaminant Neige fraiche (B)




FIGURE 29 – Influence de la vitesse sur le CFL pour le contaminant NC.C.

Pour le reste des contaminants, le tableau ci-dessous montre qu'en passant de la vitesse de 65 km/h à 40 km/h, de combien la valeur maximale du CFL C se modifie :

Contaminant	$\Delta(CFLC)$ par rapport à $\Delta(V) = 25\text{km/h}$
Neige fraîche (B)	0.04
Neige fraîche (G)	0.004
N.C. (G)	0.04
N.C. (B)	0.02
NC.C.	0.02
Verglas	0.01
Glace	-0.02
SLUSH	0.05

TABLE 2 – Modification de la valeur maximale du CFL C en passant de 65 km/h à 40 km/h

On remarque que plus la vitesse augmente, plus le maximum de la valeur du CFL C diminue, sauf pour la glace qui donne une valeur qu'on n'arrive pas à expliquer (probablement à cause de l'échantillon mesuré qui est non représentatif).

Une conclusion est que le Slush est le contaminant le plus glissant à haute vitesse, avec une courbe de CFL C nettement inférieure à 65 km/h par rapport à 40 km/h.

5.2 Modèles ensemblistes

Dans cette section, des modèles ensemblistes de régression seront appliqués à chaque contaminant de la base de données. Un exemple de modèle de bagging (Bootstrap Aggregation), tel que le modèle de Forêt Aléatoire (Random Forest), ainsi qu'un modèle de boosting (XGBoost) seront utilisés.

La même méthode de stratification sera appliquée, avec plus de précision. Étant donné que les modèles seront appliqués simultanément aux deux vitesses, ce détail sera pris en compte pour stratifier par rapport au glissement (comme déjà expliqué dans la section précédente) et également par rapport à la vitesse, afin de garantir la représentativité des deux échantillons.

Une autre modification sera apportée. Sachant que les modèles basés sur les arbres de décision ne sont pas affectés par des transformations qui conservent la même monotonie sur une variable explicative, l'application de telles transformations ne changera rien, car ces modèles se basent sur la comparaison des variables avec un seuil donné. Si une transformation croissante est appliquée à cette variable, la même comparaison sera effectuée avec la transformation du seuil, ce qui signifie qu'aucun changement effectif n'est apporté.

Même si les variables du carré du glissement ainsi que l'interaction entre la vitesse et le glissement ont été conservées, le modèle n'a pas été amélioré d'une façon significative. Pour les deux raisons précédentes et pour atténuer la complexité des modèles, seules les variables de glissement et de vitesse seront conservées.

5.2.1 Résultat des modèles

Après avoir choisi les meilleurs hyperparamètres grâce à une validation croisée en 5 blocs, les hyperparamètres retenus sont les suivants : pour Random Forest : `random_state`, `n_estimators`, `max_depth`, `min_samples_split`, et `min_samples_leaf` ; pour XGBoost : `n_estimators`, `random_state`, `learning_rate`, `max_depth`, `min_child_weight`, `subsample`, et `colsample_bytree`. Les meilleures valeurs de la recherche en grille (Grid Search) ont été trouvées (Voir partie C de l'annexe).

À l'aide de ces hyperparamètres, les résultats suivants ont été obtenus :

Contaminant	R^2 test (XGBoost)	R^2 test (Random Forest)
Neige fraîche (B)	0.8540	0.8354
Neige fraîche (G)	0.9323	0.9315
N.C. (G)	0.9350	0.9185
N.C. (B)	0.9022	0.9235
NC.C.	0.9151	0.9236
Verglas	0.8411	0.8349
Glace	0.9451	0.9442
SLUSH	0.9110	0.9394

TABLE 3 – Résultats des tests R^2 pour XGBoost et Random Forest


5.2.2 Commentaires

Comme attendu, il est observable que les modèles ensemblistes ont de meilleures performances par rapport au modèle de régression linéaire. Pour le R^2 , la valeur de performance la plus faible pour XGBoost est de 0.84, et pour les forêts aléatoires, elle est de 0.83.


Pour la neige fraîche (sur béton ou sur glace), la neige compactée sur glace, le verglas et la glace, XGBoost a montré de meilleures performances par rapport au modèle des forêts aléatoires. En revanche, pour les contaminants neige compactée sur béton, neige compactée compactée et slush, les forêts aléatoires ont obtenu de meilleurs résultats.

Étant donné que les modèles ensemblistes se basent sur les arbres de décision, lorsqu'il n'y a plus de données, spécifiquement dans l'intervalle de glissement de 20 à 100, le modèle ne produira pas de résultats erronés comme les modèles de régression pour lesquels des contraintes ont été imposées pour résoudre le problème du plateau. Étant donné que le modèle ensembliste génère une fonction par morceaux, il ne respectera pas strictement les contraintes mentionnées dans la partie de la régression par morceaux.

Les graphes suivants présentent des exemples des aspects de ces modèles :



(a) XGBoost appliqué sur le contaminant N.C. (G)



(b) Random Forest appliqué sur le contaminant SLUSH

FIGURE 30 – Exemples de performances des modèles ensemblistes

6 Classification des contaminants

Cette section est dédiée à la présentation des résultats des modèles de classification déjà présentés dans la section précédente. L'objectif ici est de prédire la classe du contaminant en utilisant les variables explicatives suivantes : le glissement, la vitesse et le coefficient de frottement longitudinal (CFL C). La classification commence par une approche univariée en fixant la vitesse à 65 km/h et le pourcentage de freinage à 15%. Dans cette première phase, seul le CFL C est utilisé comme variable explicative. Ensuite, l'approche est étendue à une classification multivariée en intégrant un terme de dépendance du CFL C à la vitesse et au pourcentage de glissement (G%), permettant ainsi de capturer les interactions entre ces variables et le CFL C.

Pour simplifier l'analyse, la neige fraîche sur glace et la neige fraîche sur béton ont été regroupées, tout comme la neige compactée sur glace et la neige compactée sur béton, en les traitant comme deux types de contaminants au lieu de quatre. Cependant, ces catégories ont été séparées lors de la modélisation du CFL C, en raison du besoin de précision maximale, chaque facteur pouvant impacter le CFL C. Le CFL C est un coefficient compris entre 0 et 1, avec 95% des observations inférieures à 0,25 dans notre base de données. Lors de la modélisation, il est crucial de prendre en compte chaque facteur potentiel influençant le CFL C pour garantir la précision des prédictions.

6.1 Classification multimodale et univariée

Commencer par une analyse multimodale et univariée (vitesse 65 km/h et 15% de glissement) est une pratique courante dans le raisonnement physique. La table de données initiale est utilisée pour extraire les données correspondant à une vitesse de 65 km/h et un taux de glissement de 15%. Cette partition est ensuite nettoyée en appliquant des seuils de stabilité adaptés, avec un nouveau critère :

$$\left\{ \begin{array}{l} \text{Vitesse} = 65 \text{ km/h} \\ \text{Taux de glissement} = 15\% \\ |\text{Glissement moyen} - \text{Glissement consigne}| \leq 1 \\ \text{Valeurs de glissement moyen acceptées} \in [14\%, 16\%] \end{array} \right.$$

Un modèle de classification sera alors appliqué à cette base de données nettoyée et les résultats seront visualisés.

À la fin de cette section "Classification des contaminants", une comparaison sera faite entre les résultats de la classification multimodale et univariée et ceux de la classification multimodale et multivariée de la base de données. La répétabilité et la reproductibilité des résultats seront vérifiées en appliquant le modèle à une vitesse de 65 km/h et un taux de freinage de 15%.

6.1.1 Analyse descriptive de la partie extraite du jeu de données

La base de données brute extraite contient 202 observations, réparties de la manière suivante : 76 observations pour la neige fraîche, 45 pour la NC.C. , 42 pour la neige compactée, 15 pour la glace, 14 pour le SLUSH et 10 pour le verglas. On remarque que

les classes sont déséquilibrées, et ce déséquilibre sera encore plus visible après le nettoyage de cette partie du jeu de données.

Après nettoyage, nous avons gardé 92 observations : 38 pour la neige fraîche, 17 pour la NC.C., 19 pour la neige compactée, 12 pour la glace, 2 pour le SLUSH et 4 pour le verglas. Il est évident qu'il ne reste pas suffisamment de données pour le verglas et le SLUSH pour permettre une classification fiable. Par conséquent, nous avons décidé de classer les contaminants en quatre classes : Neige fraîche, NC.C., neige compactée et glace, en conservant uniquement les observations de ces classes.




FIGURE 31 – La relation la valeur de CFL C et la nature du contaminant

Après la préparation de cette base de données, et en se basant sur la figure ci-dessus, on peut conclure que le CFL C permet de bien classer les différents contaminants.

6.1.2 Classification supervisée

Pour cette partie de donnée, nous allons appliquer le modèle de classification par forêts aléatoires (Random Forest Classifier). Ce modèle est le plus adapté dans ce cas en raison du faible nombre d'observations (rendant le modèle XGBoost inadapté) et des classes multimodales non binaires. Bien que le modèle de régression logistique offre une meilleure interprétabilité, il présente en même temps une performance faible dans le cas d'une classification multimodale. Ce problème sera d'autant plus observable dans la classification multivariée.

Nous obtenons le rapport de classification suivant :

Classification Report (Random Forest):

	precision	recall	f1-score	support
Glacé	1.00	1.00	1.00	2
N.C.	0.60	0.75	0.67	4
NC.C.	0.80	1.00	0.89	4
Neige fraîche	1.00	0.75	0.86	8
accuracy			0.83	18
macro avg	0.85	0.88	0.85	18
weighted avg	0.87	0.83	0.84	18

Analyse des résultats de la classification

- **Précision** : La précision mesure la proportion de vraies prédictions positives parmi les prédictions positives. Dans ce rapport, la classe "Glacé" a une précision de 1.00, ce qui signifie que toutes les prédictions pour la classe "Glacé" étaient correctes. Les autres classes, à l'exception de "Neige fraîche" avec une précision de 1.00, montrent des valeurs légèrement inférieures, notamment "N.C." avec une précision de 0.60.

- **Rappel** : Le rappel mesure la proportion de vraies prédictions positives parmi toutes les instances réellement positives. La classe "Glacé" a également un rappel de 1.00, indiquant que toutes les instances de "Glacé" ont été correctement identifiées. Les classes "N.C." et "Neige fraîche" ont des rappels respectivement de 0.75, ce qui montre que certaines instances de ces classes n'ont pas été correctement identifiées.

- **F1-score** : Le F1-score est la moyenne harmonique de la précision et du rappel, offrant une mesure de la précision globale. La classe "Glacé" a un F1-score de 1.00, indiquant une excellente performance. Les autres classes ont des F1-scores variés, avec "N.C." ayant le plus bas score de 0.67, et "Neige fraîche" avec un score de 0.86.

- **Support** : Le support représente le nombre d'occurrences de chaque classe dans le jeu de données de test. Il y avait 2 occurrences de "Glacé", 4 de "N.C.", 4 de "NC.C." et 8 de "Neige fraîche".

- **Exactitude (accuracy)** : L'exactitude globale du modèle est de 0.83, indiquant que 83% des prédictions globales étaient correctes.

- **Macro moyenne (macro avg)** : La moyenne macro est la moyenne des métriques de chaque classe, sans tenir compte du support de chaque classe. Les scores montrent que le modèle a une performance équilibrée entre les différentes classes, avec une moyenne macro de 0.85 pour la précision, 0.88 pour le rappel et 0.85 pour le F1-score.

- **Moyenne pondérée (weighted avg)** : La moyenne pondérée tient compte du support de chaque classe. Les scores montrent une bonne performance globale du modèle, avec une moyenne pondérée de 0.87 pour la précision, 0.83 pour le rappel et 0.84 pour le F1-score.

En conclusion, le modèle de forêts aléatoires a montré une bonne performance glo-

bale avec une exactitude de 0.83. La classe "Glace" a été parfaitement classifiée, tandis que les classes "N.C." et "Neige fraîche" ont montré des performances légèrement inférieures. Cependant, les scores globaux suggèrent que le modèle est efficace pour classifier les contaminants dans cette base de données.

6.1.3 Visualisation des prédictions

Dans cette partie, l'objectif est de visualiser les prédictions des classes dans un tableau des prédictions et un graphe, facilitant ainsi une prédiction rapide de la classe du contaminant à partir de sa valeur du CFL C.

La valeur maximale du CFL C dans cette partie de la base de données est de 0.24, et la valeur minimale est de 0.07. Cet intervalle a été divisé en 9 sous-intervalles de 0.02 pour plus de précision. Dans chaque sous-intervalle, la probabilité d'appartenance aux différentes classes a été calculée (en prenant la moyenne des probabilités des valeurs de chaque classe dans chaque sous-intervalle), ainsi que la classe prédite et la classe réelle (en faisant un vote à la majorité). Finalement, le tableau suivant est obtenu :

CFL C Interval	Glace	N.C.	NC.C.	Neige fraîche	True Label	Predicted Label
[0.06, 0.08]	1.00	0.00	0.00	0.00	Glace	Glace
[0.08, 0.1]	1.00	0.00	0.00	0.00	Glace	Glace
[0.1, 0.12]	0.60	0.00	0.00	0.40	Glace	Glace
[0.12, 0.14]	0.00	0.00	0.00	1.00	Neige fraîche	Neige fraîche
[0.14, 0.16]	0.00	0.00	0.00	1.00	Neige fraîche	Neige fraîche
[0.16, 0.18]	0.00	0.37	0.00	0.63	Neige fraîche	Neige fraîche
[0.18, 0.2]	0.00	0.84	0.01	0.14	N.C.	N.C.
[0.2, 0.22]	0.00	0.48	0.52	0.00	N.C.	NC.C.
[0.22, 0.24]	0.00	0.21	0.79	0.00	NC.C.	NC.C.

TABLE 4 – Probabilités d'appartenance aux différentes classes pour chaque sous-intervalle de CFL C, ainsi que les classes prédites et réelles.

Nous pouvons visualiser ce tableau de prédiction sous un graphe donné dans la figure 32.

On peut également visualiser la probabilité exacte d'appartenance pour chaque valeur du CFL C à un contaminant donné dans la figure 33.




FIGURE 32 – Probabilités moyennes pour chaque intervalle CFL C




FIGURE 33 – Probabilité d'appartenance à un contaminant en fonction de CFL C

6.2 Classification multimodale et multivariée

Dans cette partie, la base de données, dont la répétabilité et la reproductibilité ont été vérifiées, est utilisée pour effectuer une classification des contaminants (sans verglas, car il affaiblit les performances du modèle en raison du nombre minimal d'observations et de leur distribution dispersée au niveau du CFL). La classification commence par une régression logistique, suivie d'une explication sur l'inadéquation de ce modèle pour ce

problème. Ensuite, un modèle de forêts aléatoires et XGBoost sera entraîné et appliqué aux observations avec une vitesse de 65 km/h et un taux de glissement de 15%. Enfin, une comparaison des résultats obtenus sera faite avec ceux de la partie précédente.

6.2.1 Régression logistique

En appliquant un modèle de régression logistique, nous obtenons les résultats suivants :

	precision	recall	f1-score	support
Glace	0.83	0.90	0.86	21
N.C.	0.41	0.18	0.25	49
NC.C.	0.59	0.57	0.58	47
Neige fraiche	0.68	0.75	0.71	64
SLUSH	0.24	0.57	0.34	14
accuracy			0.57	195
macro avg	0.55	0.60	0.55	195
weighted avg	0.57	0.57	0.55	195

Nous constatons que la régression logistique présente une précision, un rappel et un F1-score globalement faibles, avec une exactitude (accuracy) de 0.57. Les classes "Glace" et "Neige fraîche" ont les meilleurs scores, tandis que les classes "N.C." et "SLUSH" montrent des performances particulièrement faibles.

Le modèle de régression logistique multimodale ne donne souvent pas de bonnes performances en raison de plusieurs problèmes spécifiques. L'hypothèse de linéarité de la régression logistique est trop restrictive pour notre problème, car les relations entre les variables indépendantes et les résultats sont non linéaires. De surcroît, notre base de données souffre d'un déséquilibre des classes, où certaines classes sont largement sous-représentées, ce qui rend difficile la prédiction correcte des classes minoritaires. Bien que la régression logistique puisse être étendue à des problèmes multiclassés via la régression logistique multinomiale, elle reste limitée par les problèmes susmentionnés.

Voici le tableau des coefficients de régression logistique :

	Moyenne CFL C	Moyenne G% [%]	Vitesse_65	V*CFL	g*CFL	g*V*CFL	Intercept
Glace	0.193905	0.638209	-0.202714	0.247852	-5.712532	0.239948	-0.140104
N.C.	1.353869	-0.186966	-0.374492	0.550029	1.566042	0.029946	0.098361
NC.C.	3.071972	-0.244752	-0.349550	1.232870	1.976150	-0.045737	-0.432769
Neige fraiche	1.253967	-0.042500	0.902077	0.441782	0.658888	-0.117012	-0.481754
SLUSH	-5.873712	-0.163992	0.024679	-2.472533	1.511451	-0.107146	0.956265

FIGURE 34 – Coefficients de régression logistique

Bien que ce modèle soit interprétable grâce à ses coefficients, étant donné ses faibles performances, interpréter ces résultats n'aura aucun sens car cela conduirait à de fausses interprétations.

6.2.2 Random Forest Classifier

Pour obtenir le meilleur modèle de forêts aléatoires, nous allons rechercher la meilleure combinaison d'hyperparamètres par validation croisée stratifiée en 5 blocs. Les hyperparamètres à optimiser sont : "random state", "n estimators", "max depth", "min samples split", "min samples leaf" et "class weight" (poids des classes, utilisé pour gérer le déséquilibre des classes). Nous choisirons le meilleur candidat parmi 405 combinaisons possibles, ce qui entraîne 2025 ajustements (en raison de la validation croisée en 5 blocs).

La meilleure combinaison des hyperparamètres est :

```
{'class_weight': 'balanced', 'max_depth': 12, 'min_samples_leaf': 1,
'min_samples_split': 3, 'n_estimators': 100, 'random_state': 61}
```

nous avons obtenu les résultats suivants :

Classification Report:

	precision	recall	f1-score	support
Glace	0.86	0.90	0.88	21
N.C.	0.68	0.61	0.65	49
NC.C.	0.73	0.74	0.74	47
Neige fraîche	0.80	0.86	0.83	64
SLUSH	0.75	0.64	0.69	14
accuracy			0.76	195
macro avg	0.76	0.75	0.76	195
weighted avg	0.76	0.76	0.76	195

- **Précision** : La classe "Glace" a une précision de 0.86, "N.C." a 0.68, "NC.C." a 0.73, "Neige fraîche" a 0.80, et "SLUSH" a 0.75. Ces valeurs montrent que le modèle est assez précis pour la plupart des classes, bien que "N.C." ait une précision légèrement inférieure.

- **Rappel** : La classe "Glace" a un rappel de 0.90, "N.C." a 0.61, "NC.C." a 0.74, "Neige fraîche" a 0.86, et "SLUSH" a 0.64. Le modèle a une bonne capacité à identifier correctement les instances positives pour la plupart des classes, avec un rappel particulièrement élevé pour "Glace" et "Neige fraîche".

- **F1-score** : La classe "Glace" a un F1-score de 0.88, "N.C." a 0.65, "NC.C." a 0.74, "Neige fraîche" a 0.83, et "SLUSH" a 0.69. Le F1-score global du modèle est bon, surtout pour "Glace" et "Neige fraîche".

- **Support** : Il y avait 21 occurrences de "Glace", 49 de "N.C.", 47 de "NC.C.", 64 de "Neige fraîche" et 14 de "SLUSH".

- **Exactitude (accuracy)** : L'exactitude globale du modèle est de 0.76, indiquant que 76% des prédictions globales étaient correctes.

- **Macro moyenne (macro avg)** : Les scores montrent une performance équilibrée entre les différentes classes, avec une macro moyenne de 0.76 pour la précision, 0.75 pour le rappel et 0.76 pour le F1-score.

- **Moyenne pondérée (weighted avg)** : Les scores montrent une bonne performance globale du modèle, avec une moyenne pondérée de 0.76 pour la précision, 0.76 pour le rappel et 0.76 pour le F1-score.

En conclusion, le modèle de forêts aléatoires a montré une bonne performance globale avec une exactitude de 0.76. La classe "Glace" a été particulièrement bien classifiée, tandis que les classes "N.C." et "SLUSH" ont montré des performances légèrement inférieures.

6.2.3 XGBoost Classifier

Pour obtenir le meilleur modèle de classification avec XGBoost, nous avons effectué une recherche des meilleures combinaisons d'hyperparamètres via une validation croisée stratifiée en 5 blocs. Les hyperparamètres optimisés sont : `random_state`, `n_estimators`, `max_depth`, `min_child_weight`, `learning_rate`, `colsample_bytree` et `subsample`.

Nous avons sélectionné le meilleur modèle parmi 4608 combinaisons possibles, ce qui a conduit à 23040 ajustements en raison de la validation croisée en 5 blocs. Le temps total d'entraînement du modèle a été d'environ 25 minutes, bien que nous ayons utilisé tous les cœurs de la machine grâce à l'hyperparamètre `n_jobs`. Finalement, en équilibrant les classes (en attribuant des poids à chaque classe en fonction de leur effectif), on a pu compenser les déséquilibres dans les données et améliorer les performances du modèle. la meilleure combinaison des hyperparamètres est la suivante :

```
{'colsample_bytree': 0.8, 'learning_rate': 0.2, 'max_depth': 5,
'min_child_weight': 3, 'n_estimators': 150, 'random_state': 45,
'subsample': 0.8}
```

Nous avons obtenu les résultats suivants :

Classification Report:

	precision	recall	f1-score	support
Glace	0.87	0.95	0.91	21
N.C.	0.69	0.63	0.66	49
NC.C.	0.74	0.74	0.74	47
Neige fraiche	0.83	0.89	0.86	64
SLUSH	0.82	0.64	0.72	14
accuracy			0.78	195
macro avg	0.79	0.77	0.78	195
weighted avg	0.78	0.78	0.78	195

- **Précision** : La classe "Glace" a une précision de 0.87, "N.C." a 0.69, "NC.C." a 0.74, "Neige fraîche" a 0.83, et "SLUSH" a 0.82. Ces valeurs montrent que le modèle est assez précis pour la plupart des classes, bien que "N.C." ait une précision légèrement inférieure.

- **Rappel** : La classe "Glace" a un rappel de 0.95, "N.C." a 0.63, "NC.C." a 0.74, "Neige fraîche" a 0.89, et "SLUSH" a 0.64. Le modèle a une bonne capacité à identifier correctement les instances positives pour la plupart des classes, avec un rappel particulièrement élevé pour "Glace" et "Neige fraîche".

- **F1-score** : La classe "Glace" a un F1-score de 0.91, "N.C." a 0.66, "NC.C." a 0.74, "Neige fraîche" a 0.86, et "SLUSH" a 0.72. Le F1-score global du modèle est bon, surtout pour "Glace" et "Neige fraîche".

- **Exactitude (accuracy)** : L'exactitude globale du modèle est de 0.78, indiquant que 78% des prédictions globales étaient correctes.

- **Macro moyenne (macro avg)** : Les scores montrent une performance équilibrée entre les différentes classes, avec une macro moyenne de 0.79 pour la précision, 0.77 pour le rappel et 0.78 pour le F1-score.

- **Moyenne pondérée (weighted avg)** : Les scores montrent une bonne performance globale du modèle, avec une moyenne pondérée de 0.78 pour la précision, 0.78 pour le rappel et 0.78 pour le F1-score.

On peut conclure que le modèle XGBoost est le modèle le plus performant parmi ceux que nous avons testés. Il a amélioré les performances pour toutes les classes par rapport aux modèles précédents. Finalement, les scores globaux suggèrent que le modèle est efficace pour classer les contaminants.

6.2.4 Observations pour une vitesse de 65 km/h et g=15%

Nous appliquons le modèle précédent (le modèle XGBoost puisqu'il est le plus performant) aux observations à une vitesse de 65 km/h et un glissement de 15%, et nous répétons le même travail effectué dans la section précédente. Finalement, nous obtenons le tableau suivant :

Ce tableau de prédiction peut être visualisé sous forme de graphe. De plus, il est possible de visualiser la probabilité exacte d'appartenance pour chaque valeur du CFL C à un contaminant donné à l'aide des figures ci-dessous.

CFL C Interval	Glace	N.C.	NC.C.	Neige fraiche	True Label	Predicted Label
[0.06, 0.08]	1.00	0.00	0.00	0.00	Glace	Glace
[0.08, 0.1]	0.99	0.00	0.00	0.01	Glace	Glace
[0.1, 0.12]	0.51	0.01	0.00	0.44	Glace	Glace
[0.12, 0.14]	0.00	0.01	0.00	0.96	Neige fraiche	Neige fraiche
[0.14, 0.16]	0.00	0.02	0.00	0.94	Neige fraiche	Neige fraiche
[0.16, 0.18]	0.00	0.10	0.01	0.86	Neige fraiche	Neige fraiche
[0.18, 0.2]	0.00	0.56	0.33	0.11	N.C.	N.C.
[0.2, 0.22]	0.00	0.58	0.41	0.01	N.C.	N.C.
[0.22, 0.24]	0.00	0.40	0.60	0.00	NC.C.	NC.C.
[0.24, 0.26]	0.00	0.17	0.83	0.00	NC.C.	NC.C.

TABLE 5 – Probabilités d’appartenance aux différentes classes pour chaque intervalle de CFL C, ainsi que les classes prédites et réelles.




FIGURE 35 – Probabilités moyennes pour chaque intervalle CFL C

6.2.5 Commentaire

D’après les graphes précédents, on peut dire que nous avons obtenu des résultats semblables à celles du premier modèle spécifique pour la vitesse de 65 km/h et le glissement de 15%. La différence réside au niveau de la base de données utilisée. Pour le premier modèle, nous avons utilisé la première base de données adaptée à l’ensemble des données extraites, tandis que pour le deuxième modèle, nous avons utilisé la base de données préparée précédemment.

Pour créer le graphe et le tableau, nous avons utilisé un vote à la majorité et les moyennes des probabilités pour chaque intervalle. C’est pourquoi certaines sommes des




FIGURE 36 – Probabilité d'appartenance à un contaminant en fonction de CFL C

probabilités tendent vers 1 sans être exactement égales à 1. Pour obtenir une plus grande précision, il serait préférable d'utiliser les valeurs exactes de CFL C.

Pour un CFL C supérieur à 0.175, une instabilité dans la prédiction des deux contaminants, N.C. et NC.C., commence à apparaître. Cela est dû, comme on peut le voir dans la figure 26, au chevauchement des valeurs de ces deux contaminants. De plus, il y a une similitude entre les deux contaminants, puisqu'il s'agit de neige compactée.

6.3 Ajout de l'écart entre le CFL F et le CFL C comme variable explicative

Dans la dernière partie de l'analyse exploratoire, une analyse de la variance (ANOVA) a montré que l'écart entre le CFL F et le CFL C discrimine la nature des contaminants. Cependant, il s'agissait d'une analyse descriptive. Dans cette sous-section, l'effet marginal de l'ajout de cet écart sur la précision du modèle de boosting précédent sera étudié.

Le meilleur modèle a été sélectionné parmi 17 280 combinaisons possibles, ce qui a conduit à 86 400 ajustements en raison de la validation croisée en 5 blocs. Le temps total d'entraînement du modèle a été d'environ 75 minutes, en utilisant tous les cœurs de la machine. Finalement, en équilibrant les classes, la meilleure combinaison d'hyperparamètres est la suivante :

```
{'colsample_bytree': 0.7, 'learning_rate': 0.1, 'max_depth': 10,
'min_child_weight': 1, 'n_estimators': 100, 'random_state': 13,
'subsample': 0.8}
```

Les résultats obtenus sont les suivants :

Classification Report:

	precision	recall	f1-score	support
Glacé	1	1	1	21
N.C.	0.76	0.78	0.77	49
NC.C.	0.88	0.89	0.83	47
Neige fraîche	0.84	0.91	0.87	64
SLUSH	0.69	0.64	0.67	14
accuracy			0.84	195
macro avg	0.83	0.82	0.83	195
weighted avg	0.84	0.84	0.84	195

Ces résultats confirment l'analyse précédente : l'ajout de l'écart entre le CFL C et le CFL F améliore significativement l'exactitude du modèle, qui passe de 0,78 à 0,84, ce qui est une valeur élevée. De plus, la précision et le rappel de tous les contaminants s'améliorent. Le f1-score augmente également, à l'exception du Slush où la précision diminue. En général, ce modèle est le meilleur modèle de classification parmi ceux précédemment testés, confirmant que l'écart entre le CFL F et le CFL C possède un pouvoir discriminant avec un effet marginal important.

Si la vitesse est fixée à 65 km/h et le glissement à 15%, on dispose de deux variables : le CFL C et l'écart entre CFL F et CFL C. Bien qu'un graphe en 3 dimensions puisse être visualisé, pour des raisons de clarté, seul le tableau des classes prédites et des classes réelles sera présenté.

CFL C Interval	Glacé	N.C.	NC.C.	Neige fraîche	True Label	Predicted Label
(0.06, 0.08]	1.00	0.00	0.00	0.00	Glacé	Glacé
(0.08, 0.10]	0.98	0.00	0.00	0.01	Glacé	Glacé
(0.10, 0.12]	0.67	0.01	0.01	0.30	Glacé	Glacé
(0.12, 0.14]	0.01	0.02	0.01	0.88	Neige fraîche	Neige fraîche
(0.14, 0.16]	0.00	0.03	0.00	0.95	Neige fraîche	Neige fraîche
(0.16, 0.18]	0.00	0.12	0.01	0.86	Neige fraîche	Neige fraîche
(0.18, 0.20]	0.00	0.67	0.22	0.10	N.C.	N.C.
(0.20, 0.22]	0.00	0.57	0.42	0.01	N.C.	N.C.
(0.22, 0.24]	0.00	0.39	0.60	0.00	NC.C.	NC.C.
(0.24, 0.26]	0.00	0.16	0.84	0.00	NC.C.	NC.C.

TABLE 6 – Probabilités d'appartenance aux différentes classes pour chaque intervalle de CFL C, ainsi que les classes prédites et réelles.

Le tableau présente des résultats parfaits. Il est important de rappeler que pour créer le tableau, un vote à la majorité a été utilisé, ainsi que les moyennes des probabilités pour chaque intervalle, c'est pourquoi certaines sommes des probabilités tendent vers 1 sans être exactement égales à 1

Conclusion

Ce rapport a été conçu pour explorer en profondeur la modélisation du CFL, un indicateur crucial dans l'évaluation de l'adhérence des pistes, en particulier sous l'influence des contaminants hivernaux. L'étude s'articule autour de trois composantes principales, chacune offrant une perspective approfondie sur les facteurs influençant cet indicateur.

Dans la première partie, des seuils de validité ont été établis pour identifier et éliminer les observations instables de la base de données. Ensuite, la qualité des données a été évaluée en analysant la répétabilité et la reproductibilité des mesures du CFL C, assurant ainsi que les données utilisées pour la modélisation sont robustes et fiables.

La deuxième partie a porté sur la modélisation du CFL en relation avec les contaminants hivernaux et d'autres variables explicatives, en utilisant des méthodes linéaires et des approches ensemblistes. Cette analyse a mis en lumière les schémas complexes de variation du CFL en fonction des différents types de contaminants présents sur les pistes.

Enfin, la troisième partie s'est concentrée sur la classification des contaminants, principalement en fonction de la valeur du CFL C.

Bien que ce projet repose sur une méthodologie rigoureuse et des contraintes physiques et mathématiques bien définies, des pistes d'amélioration restent envisageables :

Mesures des variables : Même si la forme des observations sur un intervalle donné est parfois bien comprise, il est essentiel d'obtenir des échantillons de valeurs pour les études statistiques, malgré le coût potentiel accru des mesures. Par exemple, si des valeurs de glissement avaient été disponibles dans l'intervalle de 20 à 100 pour tous les contaminants, il n'aurait pas été nécessaire d'imposer des contraintes sur le CFL C dans cet intervalle. Cela aurait permis d'améliorer la précision du modèle en s'appuyant sur des données réelles plutôt que sur des contraintes physiques, mais physiquement il s'agit d'une plage de freinage inutilisée.

Quantité de la base de données : Le nombre d'observations disponibles pour ce projet était relativement limité. Après l'analyse de la qualité des données, la quantité de données a été réduite de plus de 50%. Il est bien connu que la taille de la base de données joue un rôle crucial dans la précision et la performance des modèles. Un plus grand nombre d'observations aurait permis de construire des modèles plus robustes.

Précision des appareils de mesure : L'imprécision des appareils de mesure a conduit à la suppression de plusieurs observations. Toutefois, grâce à l'étude de reproductibilité et répétabilité, les incertitudes ont été considérablement réduites. Si l'étalonnage des capteurs des différentes machines est correct, cela limite les incertitudes sur le résultat final. Il serait néanmoins bénéfique d'investir dans des équipements de mesure encore plus précis pour améliorer la fiabilité des données collectées.

Faible occurrence des conditions hivernales : La compréhension des phénomènes physiques liés aux contaminants hivernaux reste limitée, en grande partie en raison de la rareté des données disponibles. Cette faible occurrence a freiné le développement d'une modélisation suffisamment précise pour offrir une vision complète de l'impact de ces conta-

minants. Une meilleure collecte de données dans des conditions hivernales variées serait nécessaire pour combler cette lacune.

Avancées et perspectives : Grâce au modèle développé dans ce projet, il est désormais possible de fournir la probabilité d'un état de surface à partir du CFL opérationnel mesuré, avec un niveau de confiance très élevé. Cela représente une avancée majeure dans l'estimation de l'état de glissance des chaussées aéronautiques, notamment en lien avec le GRF (Global Reporting Format) et ses RWYCC (Runway Condition Code), réaffirmant ainsi l'importance des mesures d'adhérence opérationnelle dans les outils d'évaluation de l'adhérence des pistes. De plus, la modélisation du CFL C selon chaque contaminant pour différents points de fonctionnement contribuera à la modélisation des performances de freinage des avions sur piste contaminée. Aussi la modélisation linéaire par morceaux avec pénalisation du CFL C garantit une transition continue et réaliste entre les segments du modèle. Cette approche permet d'adapter le modèle aux contraintes physiques tout en améliorant la précision des prédictions pour différents contaminants. Elle représente une avancée significative dans l'évaluation de l'adhérence en conditions hivernales.

En conclusion, ce projet a significativement amélioré l'estimation de l'état de surface des pistes en conditions hivernales en réduisant les incertitudes des mesures d'adhérence grâce à des modèles avancés, notamment la modélisation linéaire par morceaux avec pénalisation. Pour aller plus loin, l'amélioration des équipements de mesure et l'enrichissement des données restent cruciaux afin de perfectionner la modélisation des performances de freinage sur pistes contaminées.

Références

- [1] *MESURE DE L'ADHERENCE DES CHAUSSEES ROUTIERES* <https://www.idrrim.com/ressources/publications/1/356,Note11.pdf>
- [2] *Torque Distribution Algorithm for an Independently Driven Electric Vehicle Using a Fuzzy Control Method*, https://www.researchgate.net/figure/Relationship-between-slip-ratio-and-friction-coefficient_fig8_282520290.
- [3] *Random Forest Algorithm Explained* <https://anasbrital98.github.io/blog/2021/Random-Forest/>
- [4] PHILIPPE BESSE & BÉATRICE LAURENT, *Apprentissage Statistique : modélisation, prévision et data mining*, https://www.senenews.com/wp-content/uploads/2013/10/Appren_stat.pdf.

Annexe

A Présentation des critères de validation pour le reste des contaminants

Neige fraîche (G)

Pour le contaminant Neige fraîche (G), représentant 306 observations dans la base de données initiale, les seuils de validation du glissement sont définis en fonction de la moyenne du pourcentage de glissement ($G\%$).

Critères de Validation du Glissement :

$$\text{Seuil} = \begin{cases} 0.4 & \text{si } G\% < 3 \\ 0.8 & \text{si } G\% < 10 \\ 1.4 & \text{si } 10 \leq G\% \leq 20 \\ 5 & \text{si } G\% > 20 \end{cases}$$

Autres Critères de Validation

$$\begin{cases} \text{Deuxième critère} & : & \text{Seuil} = 15 \\ \text{Troisième critère} & : & \text{Seuil} = 5 \end{cases}$$

Résultats de l'Application des Seuils

En appliquant ces seuils, sur 306 observations initiales pour le contaminant Neige fraîche (G), 174 ont été supprimées.




FIGURE 37 – Distribution des observations gardées du contaminant Neige fraîche (G) par vitesse consigne et par glissement consigne

N.C. (G)

Pour le contaminant N.C. (G), représentant 217 observations dans la base de données initiale, les seuils de validation du glissement sont définis en fonction de la moyenne du pourcentage de glissement ($G\%$).

Critères de Validation du Glissement :

$$\text{Seuil} = \begin{cases} 0.4 & \text{si } G\% < 3 \\ 0.9 & \text{si } G\% < 10 \\ 1.5 & \text{si } 10 \leq G\% \leq 20 \\ 5 & \text{si } G\% > 20 \end{cases}$$

Par exemple, avec une moyenne de glissement de 1,5%, seules les valeurs entre 1,1% et 1,9% seront considérées comme valides. Pour une moyenne de glissement de 8%, seules les valeurs entre 7,1% et 8,9% seront valides. Avec une moyenne de glissement de 17%, les valeurs comprises entre 15,5% et 18,5% seront acceptées. Enfin, pour une moyenne de glissement de 80%, les valeurs comprises entre 75% et 85% seront acceptées.

Autres Critères de Validation

$$\begin{cases} \text{Deuxième critère} & : & \text{Seuil} = 18 \\ \text{Troisième critère} & : & \text{Seuil} = 6 \end{cases}$$

Par exemple, lorsque la masse est centrée sur 180 kg, les observations entre 162 kg et 198 kg seront validées pour le deuxième critère. Pour le troisième critère, les valeurs de moyenne des masses comprises entre 174 kg et 186 kg seront tolérées.

Résultats de l'Application des Seuils

Après application de ces seuils, 94 des 217 observations initiales ont été supprimées pour le contaminant N.C. (G).




FIGURE 38 – Distribution des observations gardées du contaminant N.C. (G) par vitesse consigne et par glissement consigne

N.C. (B)

Pour le contaminant N.C. (B), représentant 217 observations dans la base de données initiale, les seuils de validation du glissement sont définis en fonction de la moyenne du pourcentage de glissement ($G\%$).

Critères de Validation du Glissement :

$$\text{Seuil} = \begin{cases} 0.25 & \text{si } G\% < 3 \\ 0.7 & \text{si } G\% < 10 \\ 1.3 & \text{si } 10 \leq G\% \leq 20 \\ 5 & \text{si } G\% > 20 \end{cases}$$

Par exemple, avec une moyenne de glissement de 2,5%, seules les valeurs entre 2,25% et 2,75% seront considérées comme valides. Pour une moyenne de glissement de 9%, seules les valeurs entre 8,3% et 9,7% seront valides. Avec une moyenne de glissement de 14%, les valeurs comprises entre 12,7% et 15,3% seront acceptées. Enfin, pour une moyenne de glissement de 80%, les valeurs comprises entre 75% et 85% seront acceptées.

Autres Critères de Validation

$$\begin{cases} \text{Deuxième critère} & : & \text{Seuil} = 15 \\ \text{Troisième critère} & : & \text{Seuil} = 5 \end{cases}$$

Par exemple, lorsque la masse est centrée sur 180 kg, les observations entre 165 kg et 195 kg seront validées pour le deuxième critère. Pour le troisième critère, les valeurs de moyenne des masses comprises entre 175 kg et 185 kg seront tolérées.

Résultats de l'Application des Seuils

Après application de ces seuils, 69 des 217 observations initiales ont été supprimées pour le contaminant N.C. (B).




FIGURE 39 – Distribution des observations gardées du contaminant N.C. (B) par vitesse consigne et par glissement consigne

Verglas

Pour le premier contaminant, le verglas, représentant 120 observations dans la base de données initiale, les seuils de validation du glissement sont définis en fonction de la moyenne du pourcentage de glissement ($G\%$).

Critères de Validation du Glissement :

$$\text{Seuil} = \begin{cases} 0.8 & \text{si } G\% < 10 \\ 1.8 & \text{si } 10 \leq G\% \leq 20 \\ 5 & \text{si } G\% > 20 \end{cases}$$

Par exemple, avec une moyenne de glissement de 8%, seules les valeurs entre 7,2% et 8,8% seront considérées comme valides. Pour une moyenne de glissement de 15%, les valeurs comprises entre 13,2% et 16,8% seront acceptées. Enfin, avec une moyenne de glissement de 80%, les valeurs comprises entre 75% et 85% seront acceptées.

Autres Critères de Validation

$$\begin{cases} \text{Deuxième critère} & : \text{Seuil} = 20 \\ \text{Troisième critère} & : \text{Seuil} = 6.1 \end{cases}$$

Par exemple, si la masse est centrée sur 175 kg, les observations entre 155 kg et 195 kg seront validées pour le deuxième critère. Pour le troisième critère, les valeurs de moyenne des masses comprises entre 173,9 kg et 186,1 kg seront tolérées.

Résultats de l'Application des Seuils

Après application de ces seuils, 60 des 120 observations initiales ont été supprimées pour le contaminant verglas, réduisant ainsi la moitié des données. Cependant, la qualité des données est privilégiée sur leur quantité, garantissant des mesures plus fiables.




FIGURE 40 – Distribution des observations gardées du contaminant verglas par vitesse consigne et par glissement consigne

B Présentation des modèles pour le reste des contaminants

Neige fraiche (G) :

$$f(x) \cdot 10^{-5} = \begin{cases} 3764.15 + 1851.05 \cdot x - 68.1 \cdot x^2 & \text{si } x \leq 14\% \\ 18391.8 - 780.85 \cdot \log(x) & \text{si } x > 14\% \end{cases}$$




FIGURE 41 – Régression par morceau pour le contaminant Neige fraiche (G), avec $\lambda_1 = 0.0001$, $\lambda_2 = 0.003$, $\lambda_3 = 0$, $\lambda_4 = 0.0001$

N.C. (G) :

$$f(x) \cdot 10^{-5} = \begin{cases} 256.86 + 3163.16 \cdot x - 130.57 \cdot x^2 & \text{si } x \leq 12.36\% \\ 21389.96 - 789.04 \cdot \log(x) & \text{si } x > 12.36\% \end{cases}$$




FIGURE 42 – Régression par morceau pour le contaminant N.C. (G),
avec $\lambda_1 = 0.0001$, $\lambda_2 = 0$, $\lambda_3 = 0$, $\lambda_4 = 0.0005$,

N.C. (B) :

$$f(x) \cdot 10^{-5} = \begin{cases} 4010.28 + 2310.86 \cdot x - 76.62 \cdot x^2 & \text{si } x \leq 16.11\% \\ 28383.27 - 2529.23 \cdot \log(x) & \text{si } x > 16.11\% \end{cases}$$




FIGURE 43 – Régression par morceau pour le contaminant N.C. (B),
avec $\lambda_1 = 0.05$, $\lambda_2 = 0.0025$, $\lambda_3 = 0$, $\lambda_4 = 0.0002$

Verglas :

$$f(x) \cdot 10^{-5} = \begin{cases} 6773.91 + 1167.47 \cdot x - 44.01 \cdot x^2 & \text{si } x \leq 14.05\% \\ 17066.76 - 975.27 \cdot \log(x) & \text{si } x > 14.05\% \end{cases}$$




FIGURE 44 – Régression par morceau pour le contaminant Verglas, avec $\lambda_1 = 0.005$, $\lambda_2 = 0.002$, $\lambda_3 = 0.01$, $\lambda_4 = 0.0005$,

C Valeurs des hyperparamètres après optimisation avec la validation croisée 5 blocs

C.1 Random Forest Regressor

Contaminant	max_depth	min_samples_leaf	min_samples_split	n_estimators	random_state
Neige fraîche (B)	4	2	2	100	57
Neige fraîche (G)	5	1	3	30	49
N.C. (G)	5	2	2	30	60
N.C. (B)	5	1	3	40	60
NC.C.	4	1	3	120	2
Verglas	2	1	4	80	40
Glace	4	2	2	30	2
SLUSH	5	2	2	30	60

TABLE 7 – Hyperparamètres optimisés pour Random Forest Regressor

C.2 XGBoost Regressor

Contaminant	colsample_bytree	learning_rate	max_depth	min_child_weight	n_estimators	random_state	subsample
Neige fraîche (B)	1.0	0.050	5	2	80	76	0.8
Neige fraîche (G)	1.0	0.100	5	2	30	49	0.8
N.C. (G)	1.0	0.100	5	2	30	42	0.7
N.C. (B)	1.0	0.100	5	2	30	60	0.8
NC.C.	1.0	0.100	5	2	30	2	0.7
Verglas	1.0	0.095	5	1	35	42	0.7
Glace	1.0	0.100	4	3	30	60	0.7
SLUSH	0.7	0.095	3	3	80	2	0.7

TABLE 8 – Hyperparamètres optimisés pour XGBoost Regressor